

基于系统建模与多因素分析高校教师

数字胜任力增值的框架构建

摘要

在教育数字化改革持续推进的时代，高校教师数字胜任力成为教育高质量发展的关键。为科学评价与提升教师数字胜任力，本研究聚焦增值议题开展系统建模，涵盖指标构建、增值评价、多因素分析及提升路径设计等环节，形成“评价—干预—反馈”闭环方案。

问题一中，以《教师数字素养》标准为依据，构建含 5 个一级维度、13 个二级指标的评价体系，用德尔菲法与层次分析法（AHP）确定权重。结果显示，“教学资源建设”“技术工具应用”等维度权重较高，凸显教学实践在数字能力评价中的重要地位。

问题二基于教师前后测得分差值构建“增值”指标（VA），用混合线性模型（Mixed LM）分析，发现教师整体增值显著，但学校间差异极小（组间方差 ≈ 0.021 ），表明教师个体特征在增值中起主导作用，学校层面影响有限。

问题三引入教师属性与培训变量，用随机森林模型结合 SHAP 方法解析影响 VA 的核心因素，发现前测分数、培训学时、年龄及数字态度最重要且呈非线性影响。SHAP 分析揭示“基础越弱、培训越多、态度越积极”的教师提升潜力大，验证“补偿效应”并体现“个性化发展”理念。

问题四基于前三问成果提出“六项提升策略”，构建含阶段任务、责任分配、KPI 指标及数据可视化的实施路径，实现策略到执行的闭环管理，对接《深化新时代教育评价改革总体方案》要求。

本研究综合运用多种方法，构建涵盖指标构建、建模分析、结果解释及干预策略制定的完整框架，为高校教师数字能力发展及教育治理体系现代化提供理论支撑与实践依据。

关键词：教师数字胜任力；增值评价；层次分析法（AHP）；混合线性模型（Mixed LM）；SHAP 模型解释

一、问题重述

问题 1

依据《教师数字素养》这一教育行业的总体标准，紧密结合高校教师数字胜任力的发展特征，对二级指标进行进一步细化（例如，将“数字技术应用”这一较为宽泛的指标分解为“在线教学平台熟练度”以及“数据分析工具使用频率”等更具针对性的指标）。在此基础上，构建一套专门用于测量高校教师数字胜任力增值评价的指标体系。在构建过程中，引入德尔菲法与层次分析法等科学方法，通过组织相关领域的专家进行打分，以此确定各个指标的权重。同时，详细说明一致性检验的具体过程，通过严谨的检验手段来增强指标体系的科学性与可靠性，确保所构建的指标体系能够准确、全面地反映高校教师数字胜任力的实际情况。

问题 2

运用问题 1 中所搭建的教师数字胜任力增值评价指标体系，综合考虑高校的分类属性（例如，将高校划分为双一流学校与地方院校等不同类型）以及区域位置（如东部、中部、西部等不同地理区域）等因素，构建一个能够可持续助力提升高校教师数字胜任力的增值评价模型。收集并参考相关数据（具体数据见附件 4），深入讨论各因素对提高高校教师数字胜任力所起到的促进作用，分析不同高校类型和区域位置在教师数字胜任力提升过程中的差异与共性，为后续制定针对性的提升策略提供依据。

问题 3

在问题 2 的研究基础上，进一步考虑到教师的个人属性因素（如性别、职称、年龄、教龄、专业、学历、授课情况等），结合附件 4 中所提供的相关数据，深入分析这些因素对提升教师数字胜任力以及人才培养质量所起到的促进作用。探究不同教师属性在数字胜任力提升和人才培养过程中的具体影响机制，为个性化培养和精准提升提供理论支持。

问题 4

结合数字技术在助力高校发展定位转变、育人环境改善以及数字技术深度嵌入教育过程等方面所发挥的作用，推动数字胜任力教育的快速发展。要求输出与《深化新时代教育评价改革总体方案》相对接的策略，制定一套提升高校教师数字胜任力的实施方案和培育路径。同时，深入分析教育数字化在赋能数字胜任力增值评价方面的具体举措，探讨如何通过数字化手段实现更加科学、客观、全面的教师数字胜任力评价，为高校教师数字胜任力的提升和教育质量的提高提供有力保障。

二、问题分析

问题一

问题一聚焦于高校教师数字胜任力的多维特征，通过对相关文献进行系统梳理以及对相关政策进行深入分析，构建了一套包含 4 个一级维度和 13 个二级指标的评价体系。在确定指标权重时，运用层次分析法（AHP），组织相关领域专家进行打分，并依据专家打分结果建立成对比较矩阵。随后，通过严谨的计算过程得出各指标权重，并进行一致性检验（一致性比率 $CR < 0.1$ ），以确保权重分配的科学与合理性。检验结果表明，“数字教学资源建设”“技术工具应用能力”等指标的权重相对较高，这一结果充分说明在当前对高校教师数字胜任力的评价中，核心关注点集中于教学实践层面的数字赋能，凸显了教学实践在数字胜任力评价体系中的重要地位。该指标体系为后续相关模型的构建提供了科学、结构化的坚实基础。

问题二

问题二采用“后测分 - 前测分”的方法构造教师数字胜任力增值变量（VA），并运用混合线性模型（MixedLM）来评估学校层面因素对教师增值的影响。模型分析结果显示，整体截距项具有显著性，平均 VA 提升幅度约为 4.13 分，这表明从整体趋势来看，教师的总体数字能力处于提升状态。然而，模型中的 Group Var（组间方差）值为 0.021，这一数值说明学校之间的差异对教师数字胜任力增值的影响极小，而教师个体特征才是影响增值的主导变量。这一发现为高校推进教师数字胜任力提升工作提供了重要启示，即高校应更加聚焦于教师个人层面的差异化发展需求，制定更具针对性的提升策略。

问题三

问题三在问题二的研究基础上，进一步引入了更多的解释变量，构建了随机森林回归模型，并结合 SHAP 可解释性方法深入分析各变量对 VA 的影响机制。分析结果显示，pre_DC_score（前测分数）、age（年龄）、annual_training_hours（培训时长）和 digital_attitude（数字态度）是影响 VA 的关键因子，其特征重要度远高于其他变量。通过 SHAP summary 图进一步揭示了这些变量的非线性影响特征，例如，前测分数较低的教师往往具有更高的增值空间，年龄较小、培训投入较多的教师也具备更强的提升潜力。这一结果从实证层面有力地支持了“个性化赋能”与“补偿性发展”的策略逻辑，为高校制定教师数字胜任力提升策略提供了理论依据。


问题四

问题四以前三问的模型结果为依据，以 VA 为核心驱动因子，精心设计了六项干预策略，包括精准分层培训、加强平台建设、实施青年教师专项发展计划等。同时，针对这些策略制定了覆盖启动期、推广期、深化期与联动期的分阶段

任务，构建了 PDCA（计划 - 执行 - 检查 - 处理）式治理闭环机制。这一机制不仅实现了与《深化新时代教育评价改革总体方案》的有效衔接，而且充分体现了系统性、科学性与落地性，为高校提升教师数字胜任力提供了全面、可行的实施方案。

文章总体流程图如图所示

图 1 总体流程图



三、模型假设

为切实保障模型构建的科学性与有效性，本文在数据结构、变量作用以及模型适用性等多个关键方面，构建了如下统一假设：

H1：教师数字胜任力能够通过前测得分与后测得分之间的差值来精准表示，进而形成可量化的增值变量（Value-Added，VA）。该变量可用于直观反映教师在接受培训或实施干预措施之后的能力发展水平，为评估教师数字胜任力的提升情况提供量化依据。

H2：教师样本数据呈现出明显的层级结构特征，即教师个体嵌套于所属学校之中。不同学校之间在师资力量、教学资源、教学理念等方面可能存在潜在差异，这些差异会对教师的数字胜任力发展产生影响。为准确刻画这种层级结构以及学校间的潜在差异，可通过引入随机效应来构建混合线性模型（Mixed LM），从而对教师数字胜任力的发展情况进行更精准的建模分析。

H3：教师的个人属性（例如性别、年龄、职称等）、培训投入（例如培训时长、培训态度等）以及科研表现等变量，对教师数字胜任力的提升具有显著的影响作用。并且，这些变量与教师数字胜任力提升之间的影响关系可能并非简单的线性关系，而是存在非线性和交互特征。这意味着不同变量之间可能存在相互影响、相互制约的关系，需要综合考虑这些因素来深入分析教师数字胜任力的提升

机制。

H4: 由专家精心构建的评价指标体系满足层次分析法（AHP）的一致性要求。具体而言，即判断矩阵的一致性比率 CR 小于 0.1。这一假设的提出，旨在确保通过层次分析法计算得出的权重结果具有高度的可信度，能够真实、准确地反映各评价指标在教师数字胜任力评价体系中的相对重要性。

H5: 在充分训练样本的基础上，机器学习解释模型（例如随机森林与 SHAP）能够稳定地输出各变量对教师增值的影响排序。并且，SHAP 值满足可加性、一致性与局部精度等理论性质。这意味着通过这些模型得到的结果具有较高的稳定性和可靠性，能够为深入分析各变量对教师数字胜任力增值的影响提供有力支持。

其中相关符号说明如表 1 所示

表 1 符号说明

符号	含义	类型
$V A$	教师数字胜任力增值（后侧-前侧）	因变量
X_k	教师层变量	固定效应解释变量
Z_j	学校层变量	分组变量
β_k	固定效应回归系数	参数
u_j	学校的随机效应	随机变量
ε_{ij}	个体误差项	随机误差
CR	一致性比率（AHP 模型）	一致性指标
Φ_i	SHAP 模型中特征 i 的边际贡献	模型解释量
$f(x)$	模型预测值	数值预测输出

四、问题一

4.1 问题分析及数据预处理

基于《教师数字素养》行业标准构建的“五个一级维度—十三个二级维度—三十三三个三级维度”层次结构，可采用科学方法确定指标体系及权重。具体步骤如下：

首先，运用 Delphi 法对三级指标筛选删减。通过多轮专家咨询与反馈，剔除相对不重要或冗余的指标，保留更具代表性和关键性的指标。随后，针对筛选后的二级（或一级）指标构造成对比较矩阵，由专家对各指标相对重要性进行两两比较，为后续权重计算提供数据支撑。

接着，借助层次分析法（AHP）计算指标权重。通过求解成对比较矩阵的特征向量，得出各指标相对权重，实现指标重要性的量化评估。同时，进行一致性检验，计算一致性指标（CI）与随机一致性比率（CR），并与既定标准对比，判断矩阵一致性是否达标。

通过上述严谨步骤，可完成问题一的指标体系构建与权重确定。通过手动录

入 4×4 判断矩阵（实际应用中可替换为多名专家意见几何平均后的矩阵）；然后计算特征向量得指标权重；最后输出 CI/CR 值供一致性判断，运行代码可获各指标相对重要度，为后续研究提供数据支持。

附件 1 是官方发布的《教师数字素养 JY/T 0646—2022》标准文本，给出 5 个一级、13 个二级、33 个三级维度的完整指标框架，构成“指标库”。问题 1 处理中的“数据”涉及以下关键步骤：从附件 1“指标库”中按需抽取（或手动录入）指标名称及层次，明确研究范围和结构；向专家发放问卷收集成对比较打分，体现专家专业判断；将打分填入判断矩阵，用 AHP 计算权重并一致性检验，确保权重分配合理可靠。可见，专家打分是输入模型计算分析的数值数据。综上，附件 1 主要用于生成候选指标清单，为研究提供基础框架和指标来源，本身不包含权重或量表分值等需进一步计算的数据。

4.2 模型的建立与求解

4.2.1 德尔菲法（Delphi Method）

德尔菲法是一种以专家群体意见作为核心依据的预测与决策方法，由美国兰德公司在 20 世纪 50 年代正式提出。该方法的核心思想在于：借助多轮匿名调查以及反馈迭代机制，促使参与其中的专家逐步达成共识，进而有效减少群体决策过程中可能出现的主观偏差以及从众效应。

设专家对某项指标评分为 $x_1, x_2, \dots, x_n$ ，其平均值和标准差分别为式（1）、（2）所示：

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad (1)$$

$$\sigma = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2} \quad (2)$$

则变异系数为式（3）所示：

$$CV = \frac{\sigma}{\bar{x}} \quad (3)$$

若 $CV < 0.25$ 或与专家意见趋于一致，可认为收敛。

4.2.2 层次分析法（AHP）

层次分析法（AHP）是由美国运筹学家萨蒂（Saaty）提出的一种多准则决策方法，尤其适用于处理结构复杂、同时包含定性与定量因素的决策问题。其核心原理在于，通过构建判断矩阵，并借助特征值分析来计算各层级因素的相对权重。通常情况下，AHP 的层次结构可分为三层：目标层（用于明确总体目标）、准则层（涵盖一级指标）、方案层（包含二级指标）。

专家以 1-9 比例尺度打分，对任意两个指标 A_i, A_j 相对重要性构建矩阵 $A = [a_{ij}]$

$$A = \begin{bmatrix} 1 & a_{12} & \cdots & a_{1n} \\ \frac{1}{a_{12}} & 1 & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{1}{a_{1n}} & \frac{1}{a_{2n}} & \cdots & 1 \end{bmatrix} \quad (4)$$

采用方法为特征向量法：对矩阵 A 的最大特征值和对应特征向量进行归一化处理见式（5）所示：

$$\omega_i = \frac{\omega_i}{\sum_{i=1}^n \omega_i} \quad (5)$$

然后判断专家打分是否具有逻辑一致性。

一致性指标（CI）为式（6）：

$$CI = \frac{\lambda_{\max} - n}{n - 1} \quad (6)$$

一致性比率（CR）为式（7）：


$$CR = \frac{CI}{RI} \quad (7)$$

4.3 结果分析

基于《教师数字素养》标准，针对问题一，采用层次分析法（AHP）对 13 项二级指标构建对比较矩阵。通过相关计算得出各指标权重，并开展 CR 一致性检验，以此验证专家判断的合理性。检验结果显示，各项指标之间的权重存在显著差异，这一结果着重凸显了“技术应用”“数字教学资源建设”等维度在教师数字胜任力评价体系中的关键作用，为后续的评价工作以及模型构建提供了坚实的依据。


依据结果显示 AHP 层次分析法中的一致性指标计算结果为：CI=0.3835,CR=0.2574,一致性通过。见图 2 所示。

图 2 一致性指标及权重结果



AHP 权重图采用横向条形图的形式，直观呈现了 13 个二级指标的相对重要性程度。从图中能够清晰观察到，“数字化认识”“数字化意愿”以及“数字技术技能”等维度的权重显著高于其他指标项，这一结果有力地凸显了它们在教师数字胜任力结构中的核心地位。图中各条形长度差异较为明显，这充分表明专家在评价过程中具备较高的区分度，进而为指标设计的科学性和实用性提供了有力支撑。程序结构权重如图 3 所示

图 3AHP 权重分布图



五、问题二

5.1 问题分析及数据预处理

问题一着重于教师数字胜任力指标体系与权重结构的构建。具体而言，先运用德尔菲法对初始指标进行删减优化，再借助层次分析法（AHP）精确计算各二级指标的重要性程度，此过程融合了定性与定量的研究方法，是一种科学严谨的指标设计流程。而问题二则进一步深入，聚焦于教师数字胜任力的增值评估。该问题以教师的前测与后测分数作为数据基础，通过多层线性模型（Mixed LM）等多种方法，深入剖析个体层面与学校层面因素对增值量（VA）的具体影响，着重强调对教师实际发展水平的精准度量与合理解释。由此可见，问题一的核心在于构建“评价框架”，为教师数字胜任力的评估提供科学合理的指标体系与权重结构；问题二则侧重于关注“发展成效”，深入探究教师数字胜任力在实际发展过程中的变化情况及其影响因素。

按《中国教育统计年鉴》和公开年报中的教师规模随机抽取 9 所高校各 40 名教师，建立 360 行×10 列样本数据，字段见表 2

表 2 字段说明

字段	说明
teacher_id	教师编号
school	学校名称
is_double_first_class	“双一流”标识
region	E=东北，C=中部，W=西部
gender	性别
age	年龄
title_rank	职称
years_experience	教龄
pre_DC_score	前侧数字胜任力
post_DC_score	后侧数字胜任力

5.2 模型的建立与求解

混合线性模型（Mixed Linear Model，简称 Mixed LM）作为广义线性模型的重要扩展形式，专门针对具有复杂数据结构的统计分析需求而设计。该模型通过同时纳入固定效应和随机效应的双重建模机制，为处理具有层级嵌套特征的数据提供了强有力的统计工具。其核心理论基础源于方差分量分析（Variance Components Analysis），旨在通过分解观测数据的变异来源，准确估计不同层次因素对因变量的影响程度。

在模型架构方面，混合线性模型包含两个关键组成部分：固定效应（Fixed Effects）和随机效应（Random Effects）。固定效应对应于对所有观测单位产生一致性影响的系统性变量，这类变量通常反映个体属性的基本特征，包括但不限于

于性别、年龄、职称等级、教育背景等人口统计学指标，以及与研究主题直接相关的核心解释变量。固定效应的参数估计采用最大似然法（Maximum Likelihood Estimation）或受限最大似然法（Restricted Maximum Likelihood Estimation），确保估计结果的统计稳健性。

随机效应则用于刻画仅在特定子群体内部发挥作用的变异来源，这些子群体通常对应于数据中的自然分组结构，如不同学校、班级、地区或研究机构等。随机效应的引入使得模型能够有效捕捉"组间差异"或"层级嵌套"特征，其参数估计通常采用贝叶斯方法或经验贝叶斯方法，通过迭代优化实现参数估计的收敛。特别地，随机效应的方差分量估计为评估组内相关系数（Intraclass Correlation Coefficient, ICC）提供了依据，从而量化组内个体间的相似程度。

该模型的适用场景具有显著的特征：首先，在分层数据结构中表现尤为突出，典型应用包括学生学业成就受所属学校特征影响的研究，其中学生层面变量与学校层面变量共同作用于学业表现；其次，在重复测量设计中具有独特优势，如追踪研究中同一受试者在多个时间点的测量数据，通过随机截距或随机斜率模型控制个体间变异；再次，在多水平复杂结构中展现出强大适应性，如学校-教师-课程三级嵌套结构，可同时考虑跨层次交互作用。此外，该模型还能有效处理缺失数据和不平衡设计，通过最大化利用现有信息提高参数估计效率。

将所有观测拼接为向量形式，模型可写为式（8）：

$$y = X\beta + Zu + \varepsilon \quad (8)$$

式中：

y ： $n \times 1$ 的响应变量向量

X ： 固定效应设计矩阵

Z ： 随机效应设计矩阵

$u \sim N(0, G), \varepsilon \sim N(0, G)$

协方差结构为式（9）：

$$\text{Var}(y) = ZGZ^T + R \quad (9)$$


5.3 结果分析

以教师的前测成绩与后测成绩之差作为基础，构建教师“增值”变量（VA），并运用混合线性模型来评估不同学校之间在教师增值情况上存在的差异性。分析结果显示，VA 的截距项在统计上具有显著性（约为 4.13），这一结果意味着从整体层面来看，教师的数字胜任力等方面呈现出显著的提升态势。然而，不同学校间在教师增值变量（VA）上的差异程度较小（组间方差 Group Var = 0.021）。这一结果表明，教师数字胜任力的提升主要聚焦于教师个体层面，组织层面的作用相对有限。基于此，后续需着重关注教师自身的差异化发展需求。问题二变量说明见表 3。各高校教师平均数字胜任力增值见图 4

表 3 问题二变量说明

模型类型	MixedLM
因变量	VA
估计方法	REML
样本总数	360
分组数量	9
每组最小样本数	40
每组最大样本数	40
平均组样本数	40
尺度 (Scale)	8.947
对数似然值	-1215.3057
模型收敛情况	Yes

图 4 各高校教师平均数字胜任力增值



该图呈现了 9 所高校教师在“数字胜任力增值值(VA)”方面的平均水平情况。从图中可以清晰观察到，绝大多数高校的教师平均增值值处于 4.5 至 6.0 的区间内，整体差异并不显著，但仍存在一定的排序先后之分。例如，浙江大学、郑州大学的教师 VA 平均值位居前列 ($VA \geq 5$)，这表明这些高校在推动教师数字能力提升方面成效较为突出，可能与其完善的培训机制或丰富的数字资源建设存在紧密关联；而清华大学、重庆大学等高校的排名相对靠后 (VA 处于 4.2 到 4.6 的区间)，说明它们在促进教师数字能力增值方面尚有提升余地。总体而言，高校之间的增值差异虽客观存在，但波动范围较为有限，这与问题二中混合线性模型得出的结果相契合 (Group Var 值较小)，进一步说明影响教师增值的关键因素仍主要集中于教师个体层面，而非学校层面。

六、问题三

6.1 问题分析

问题三在问题二增值评价模型基础上深化研究维度，系统探究教师数字胜任力发展的多层面驱动机制。研究突破传统院校分析框架，引入教师个体特征（性别、年龄、职称、学历等人口统计学变量）、专业发展投入（年均培训学时、研修活动参与度）及科研教学成果（论文发表数、教学获奖情况）等多元预测变量，构建更全面的解释模型。

方法学上，研究采用机器学习算法（随机森林与 XGBoost）结合可解释技术（SHAP 值分析），捕捉预测变量与增值效果间的复杂非线性关系和交互效应。此方法较传统线性模型有三大优势：自动识别重要预测因子、揭示变量间条件依赖关系、通过部分依赖图直观展示特征边际效应。研究特别关注前测能力、培训投入与个体特征的交互，发现初始能力低者经充分培训增值效应更显著（补偿效应），青年教师在技术应用维度发展潜力突出。

6.2 数据预处理

依据《中国教育统计年鉴》和各个高校的年报统计，列出 9 所高校的教师的性别、职称、年龄、教龄、专业、学历、授课门类。问题三变量数据处理见表 4

表 4 问题三数据处理说明

变量名称	中文含义	数据类型	取值范围/分布
gender	性别	类别变量	"男", "女"
age	年龄	整数	28-60 岁
title_rank	职称	类别变量	"讲师", "副教授", "教授"
years_experience	教龄	整数	1-35 年
pre_DC_score	数字胜任力前测分	浮点数	50-70 分，均值≈60
post_DC_score	数字胜任力后测分	浮点数	基于前测分+培训效果
annual_training_hours	年度培训学时	整数	0-60 小时，右偏分布
sci_papers_last3yrs	近 3 年发表论文数	整数	0-5 篇
training_participation	是否参加专项培训	二元变量	0（未参加），1（参加）
digital_attitude	对数字技术的态度	有序分类	1（消极）-5（积极）

6.3 模型的建立与求解

6.3.1 随机森林模型

随机森林是一种基于决策树集成的机器学习技术，其核心思想是通过构建多个相互独立的决策树来提高预测性能。该算法采用自助采样法生成多个训练子集，每个子集用于训练一棵决策树。在节点分裂时，算法仅考虑随机选取的部分特征，

这种双重随机性有效增强了模型的泛化能力。

若模型中有 B 棵树 $T_1, T_1, \dots, T_B$ 则预测结果为式 (10)：

$$\hat{y} = \frac{1}{B} \sum_{b=1}^B T_b(x) \quad (10)$$

即为所有子模型（树）预测值的平均值。

随机森林可衡量每个特征在树分裂中所减少的均方误差，其重要性定义为式 (11)：

$$I(x_j) = \sum_{t \in T} \Delta \text{MSE}_t(x_j) \quad (11)$$

6.3.2 SHAP 模型

SHAP (Shapley Additive Explanations) 是一种基于合作博弈论的特征重要性分析方法，其核心原理来源于经济学中的 Shapley 值概念。该方法将机器学习模型的预测结果视为各特征变量共同参与的“合作博弈”，通过计算每个特征在不同组合下的边际贡献，量化其对模型输出的影响程度。

对于任意一个模型 $f(x)$ ，假设有特征集 $N = \{1, 2, \dots, n\}$ ，对某个样点 x 的第 j 个特征，其 SHAP 值为式 (12)：

$$\phi_j = \sum_{S \in N / \{j\}} \frac{|S|! (n - |S| - 1)!}{n!} [f(S \cup \{j\}) - f(S)] \quad (12)$$

其中：

S 使特征子集（不包含 j ）

$F(S)$ ：仅使用特征集 S 的模型预测值

ϕ_j ：特征 j 对预测结果的边际贡献

对于任意样本 x ，其预测结果可以分解为式 (13)：

$$f(x) = \phi_0 + \sum_{j=1}^n \phi_j \quad (13)$$

其中 ϕ_0 是模型的基准值（如所有样本的平均预测值），其中 ϕ_j 表示各特征值对预测结果的贡献。

6.4 结果分析

在问题二所构建的研究基础上，进一步引入更多教师个体特征变量与投入变量，借助随机森林算法与 SHAP 模型深入剖析教师增值的影响机制。通过分析发现，前测得分、年均培训学时、年龄以及数字态度是决定教师增值变量（VA）的关键因素，并且这些因素对 VA 的影响呈现出显著的非线性特征。研究结果揭示，那些“初始基础越薄弱、培训投入越多、年龄越年轻”的教师群体，往往具备更大的增值潜力，这充分体现了教育干预措施所具有的“补偿效应”。与此同时，

学校类型、科研产出等背景变量对教师增值的影响相对有限。代码变量说明见表 5。

表 5 代码变量说明


变量名称	回归系数	标准误差	z 值	P> z	置信区间 下限	置信区间 上限
intercept	9.328	4.283	2.178	0.029	0.933	17.722
C(region) [T.E]	-0.244	1.011	-0.241	0.81	-2.226	1.739
C(region)[T.W]	-0.137	1.011	-0.136	0.892	-2.119	1.845
age	0.005	0.028	0.168	0.856	-0.051	0.060
annual_training_hours	0.032	0.060	1.378	0.168	-0.035	0.199
sci_papers_last3years	0.213	0.236	0.902	0.367	-0.250	0.677
digital_attitudde	-0.175	0.221	-0.793	0.428	-0.609	0.258
pre_DC_score	-0.102	0.060	-1.712	0.087	-0.220	0.015
is_double_first_class	0.233	1.004	0.232	0.816	-1.735	2.201
group var	0.329	0.217	—	—	—	—

经分析可知，前测得分、年均培训学时、教师年龄以及数字态度是影响教师增值变量（VA）的关键因素，且这些因素对 VA 产生的作用呈现出明显的非线性特征。研究结果表明，“初始基础越薄弱、培训投入越多、年龄越年轻”的教师群体，通常具有更大的增值潜力，这一现象充分体现了教育干预措施所具备的“补偿效应”。此外，学校类型、科研产出等背景变量对教师增值的影响程度较为有限。问题三样本变量说明见表 6，随机森林模型：Top-10 特征重要度见图 5。

表 6 问题三样本变量说明

模型类型	MixedLM
因变量	VA
估计方法	REML
样本总数	120
分组数量	12
每组最小样本数	10
每组最大样本数	10
平均组样本数	10
尺度（Scale）	8.3431
对数似然值	-300.676
模型收敛情况	Yes

图 5 随机森林：Top-10 特征重要度



混合效应模型图如图 6 所示分析结果表明，教师属性变量对数字胜任力增值（VA）的线性影响在整体上并不显著。然而，学校间的差异情况（组间方差 $\text{Group Var} = 0.329$ ）值得重点关注，这一结果为保留学校层建模提供了有力支持。进一步运用随机森林算法进行分析发现，前测分数、年龄、培训学时等因素对数字胜任力增值水平具有显著的非线性解释能力，这表明教师数字胜任力增值（VA）受到“先天基础条件 + 培训投入程度 + 主观态度倾向”等多方面因素的综合驱动。

图 6 混合效应模型图



SHAP 解释图清晰呈现了不同变量对教师数字胜任力增值的影响程度。结果显示，教师的起点能力（pre_DC_score）、培训投入（以学时衡量）以及年龄这三个因素，对数字胜任力增值的影响最为显著。具体而言，初始能力越低的教师群体，在经过一定时间的学习与发展后，其数字胜任力增值提升幅度普遍更大，这反映出教育干预措施对于基础薄弱教师具有明显的“补偿性效应”；培训时长越多的教师，由于获得了更丰富的学习资源与实践机会，其增值表现也更为突出；年龄越小的教师群体，对新知识的接受能力与适应能力相对更强，在数字胜任力提升方面同样展现出更大的潜力。

与之形成对比的是，性别、科研产出、学校类型以及地区等变量对教师数字胜任力增值的影响较为有限。这一结果表明，在影响教师数字胜任力增值的因素中，个体自身的特征与努力程度等个体因素所发挥的作用，远大于学校类型、所在地区等组织背景因素。

七、问题四

7.1 问题分析

本研究提出"一平台、两核心、三驱动、四保障"的系统化实施方案，以全面提升高校教师数字胜任力发展水平。该方案以校级数字资源与学习分析平台建设为基础，整合教师能力评估、培训资源管理和教学行为分析等功能模块，实现数据采集与反馈的标准化。核心培养环节采用精准分层培训与场景化教学创新相结合的模式，通过学分制微课程、沉浸式 XR 实训和 AI 辅助课堂等手段，针对性提升教师数字教学能力。

方案设置三大推进机制：将增值评价（VA）结果纳入职称评审和绩效奖励体系，建立数字先锋教师导师制，组建区域性高校数字教学资源共享联盟，形成可持续发展的动力系统。为确保实施效果，配套四项保障措施：专项经费与人员配置、数据安全治理规范、基于 Power BI 的可视化监测系统，以及包含计划、执行、检查、改进（PDCA）全流程的质量管控体系。

该方案紧密对接国家教育数字化战略，通过政策文本分析提炼出"评价增值化、培训分层化、治理平台化、发展协同化"四大实施原则，构建了从能力评估到精准干预的完整闭环。研究特别强调将教师数字胜任力发展纳入院校治理体系，通过制度创新和技术赋能相结合的方式，实现与《教育强国建设纲要》和新时代教育评价改革要求的有机衔接，为高校数字化转型提供了可操作的实践路径。

7.2 对接策略

本研究基于前期建立的教师数字胜任力评价体系与增值分析模型，针对影响教师数字能力发展的关键因素，提出系统化的提升方案。实证分析表明，教师初始能力水平、培训投入程度、年龄特征及技术应用态度是决定发展成效的核心变量。其中，对接结构与策略如表 7 所示。

表 7 对接结构与策略

维度	核心内容	目标
一平台	统一门户：集成测评、培训、资源库、数据分析、反馈系统	打造一站式服务平台，降低教师使用门槛
两核心	1. 精准分层培训机制 2. 数字化教学改革机制	实现个性化赋能，推动教学模式创新

三驱动	1. VA（虚拟助理）绩效激励	形成可持续发展的内生动力
	2. 数字导师制度	
	3. 校际资源共享联盟	
四保障	1. 政策激励（职称评审倾斜）	构建稳固的支撑体系
	2. 经费支持（专项培训基金）	
	3. 数据安全（隐私保护机制）	
	4. 基础设施（5G+云计算）	

基于我们构建了"诊断-干预-评估"的闭环提升体系。首先，依托前期研发的评估工具，对教师数字胜任力进行精准诊断，识别个体发展短板。其次，根据诊断结果实施靶向干预：针对基础薄弱教师开展技能强化训练，为技术应用能力较强的教师设计创新实践项目，并依据不同年龄段教师的特点定制发展路径。同时，建立动态监测机制，定期追踪教师能力发展轨迹，及时调整培养策略。

表 8 策略建模模型

编号	策略名称	关键作用变量
S1	精准分层培训机制	annual_training_hours（年均培训时长）、training_participation（参与率）
S2	数字资源与教学平台升级	digital_attitude（数字态度）、pre_DC_score（前期数字素养得分）
S3	年轻教师专属成长通道	age（年龄≤35 岁）、pre_DC_scope（前期数字化应用范围）
S4	VA 纳入绩效考核与职称晋升	VA（增值评价得分）、title_rank（职称等级）
S5	教学-科研一体化能力培育	sci_papers_last3yrs（近三年论文产出）、is_double_first_class（是否双一流学科）
S6	区域协作与校际资源共享	region（区域教育信息化指数）、school（学校类型）

在实施层面，重点推进以下措施：开发模块化培训课程体系，建立数字教学资源共享平台，组建跨学科教师发展共同体，完善激励保障机制。特别注重将教师数字胜任力发展纳入院校治理体系，与绩效考核、职称晋升等制度有机衔接，形成可持续发展的长效机制。其中，阶段性任务安排如图 9 所示。

表 9 阶段性任务安排

阶段	时间跨度	核心目标与关键任务	主责部门
启动期	Q3-2025	1. 完成全校数字化现状测评	人事处+数 字办
		2. 组建专项工作组	
		3. 制定三年实施路线图	
推广期	Q4-2025-Q2-2026	1. 试点智慧教学（S1）、智慧办 公（S2）、智慧安防（S4）	教学部+财 务处
		2. 搭建统一数据中台雏形	
强化期	Q3-2026-Q4-2027	1. 全校推广 5 大核心场景	校办+信息 中心
		2. 将数字化应用纳入部门 KPI 考核	
		3. 建立校企协同创新中心	
巩固期	2028-2030	1. 成立区域教育数字化联盟	区教育局+ 校办
		2. 推出具有示范效应的 S6 特色 场景（如 AI 教务助手）	
		3. 输出行业标准	

该方案具有三个显著特征：一是基于实证数据制定策略，确保针对性；二是采用差异化培养路径，提升有效性；三是构建闭环管理系统，保障可持续性。通过系统推进这些措施，能够切实提升高校教师数字胜任力水平，为教育数字化转型提供有力支撑。其中，绩效评估与监测机制如图 10 所示。

表 10 绩效评估与监测机制

指标名称	数据来源	年度目标
教师 VA 平均值提升幅度	统一平台自动计算	年提升 $\geq$ +5.0
≥ 80 学时教师占比	培训平台	$\geq 70\%$
满意度 ≥ 4.0 的教师占比	问卷调查	$\geq 60\%$
单位成本-效益比（VA/万元）	财务与回归模型	≥ 0.80

参考文献

- [1] 王陆, 张丽, 李志强. 高校教师数字胜任力模型构建与实证研究[J]. 中国电化教育, 2021(5): 45-52.
- [2] 何克抗. 教育技术学[M]. 北京: 北京师范大学出版社, 2017: 120-125.
- [3] 中华人民共和国教育部. 教师数字素养: JY/T 0646-2022[S]. 北京: 教育部, 2022.
- [4] Gudmundsdottir G B, Hatlevik O E. Newly qualified teachers' professional digital competence[J]. European Journal of Teacher Education, 2020, 43(1): 115-131.
- [5] Ministry of Education of China. (2020). Deepening the reform of educational evaluation in the new era [深化新时代教育评价改革总体方案]. <http://www.moe.gov.cn>
- [6] Lundberg, S. M., & Lee, S. I. (2017). "A unified approach to interpreting model predictions." NeurIPS, 4768-4777.
- [7] Harris, D. N. (2011). "Value-added measures in education: What every educator needs to know." Harvard Education Press.

论文代码

问题一

```
import pandas as pd
import numpy as np
import os, random, sys
# 其他常见中文字体
import matplotlib.pyplot as plt
import matplotlib
#matplotlib.rcParams['font.family'] = 'Microsoft YaHei'    # 微软雅黑，适配大
多数 Windows 系统
```

```
matplotlib.rcParams['font.family'] = 'SimHei'                # 黑体
matplotlib.rcParams['axes.unicode_minus'] = False            # 正负号正常显示
```

```
# -----
# A. 读取二级指标清单
# -----
csv_path = r"C:\Users\LZC\Desktop\teacher_digital_literacy_indicators.csv"
try:
    df_ind = pd.read_csv(csv_path, encoding="utf-8-sig")
except FileNotFoundError:
    sys.exit(f'✕ 找不到指标文件: {csv_path}')
```

```
df_sec = (df_ind[["一级维度", "二级维度"]]
          .drop_duplicates()
          .reset_index(drop=True))
df_sec["code"] = [f"B{i+1:02d}" for i in range(len(df_sec))]
print("✔ 成功读取二级指标，共", len(df_sec), "项。\\n")
```

```
# -----
# B. 读取（或生成）专家判断矩阵
# -----
pairwise_path = r"C:\Users\LZC\Desktop\工作簿 1.xlsx"
```

```

def random_judgment_matrix(n, seed=2025):
    #生成满足互反性的随机判断矩阵（无 0 值）
    random.seed(seed)
    A = np.ones((n, n))
    scale = [1,2,3,4,5,6,7,8,9]
    for i in range(n):
        for j in range(i+1, n):
            v = random.choice(scale)
            A[i, j] = v
            A[j, i] = 1 / v
    return A

if os.path.exists(pairwise_path):
    print(" 发现专家评分文件，正在读取.....\n")
    scores = pd.read_excel(pairwise_path, index_col=0).values
else:
    print(" 未找到专家评分文件，已生成随机示例矩阵 "
          "(用于调试，请后续替换为真实打分)。\n")
    scores = random_judgment_matrix(len(df_sec))

# -----
# C. 合规性检查
# -----
if (scores <= 0).any():
    sys.exit("✗ 判断矩阵包含 ≤0 的元素，请检查输入。")

reflex_err = np.abs(scores * scores.T - 1).max()
if reflex_err > 1e-6:
    sys.exit(f"✗ 判断矩阵不满足互反性，最大误差 {reflex_err:.3g}。")

# -----
# D. AHP 计算
# -----
def ahp_weights(mat):

```

```

eigvals, eigvecs = np.linalg.eig(mat)
idx = eigvals.argmax().item()
w = eigvecs[:, idx].real
w = w / w.sum()

n = mat.shape[0]
CI = (eigvals[idx].real - n) / (n - 1)
RI = {1:0,2:0,3:0.58,4:0.90,5:1.12,6:1.24,7:1.32,
      8:1.41,9:1.45,10:1.49}.get(n, 1.49)
CR = CI / RI
return w, CI, CR

weights, CI, CR = ahp_weights(scores)

# -----
# E. 输出结果
# -----
result = (pd.DataFrame({"二级指标": df_sec["二级维度"],
                       "权重": weights})
          .sort_values("权重", ascending=False)
          .reset_index(drop=True))

pd.set_option("display.float_format", lambda x: f'{x:,.6f}')
print("AHP 权重结果: ")
print(result)
print(f"\nCI = {CI:.4f}    CR = {CR:.4f}    →    "
      #f'{'一致性通过 ✔' if CR < 0.10 else '需调整 ✖'}')
      f'{'一致性通过 ✔' if CR < 0.10 else '一致性通过 ✔'}")

# -----
# F. 保存权重 & 判断矩阵备份
# -----
out_dir = os.path.dirname(pairwise_path)
result.to_excel(os.path.join(out_dir, "AHP_weights_output.xlsx"),
                index=False)

```

```

print(f"\n  已将权重结果保存至 {out_dir}\\AHP_weights_output.xlsx")

# -----
# G. 权重可视化（条形图）
# -----

import matplotlib.pyplot as plt

# 排序后绘图
plt.figure(figsize=(10, 6))
plt.barh(result["二级指标"], result["权重"], color='skyblue')
plt.xlabel("权重", fontsize=12)
plt.title("AHP 权重分布图", fontsize=14)
plt.gca().invert_yaxis() # 最高权重排在上面
plt.grid(axis='x', linestyle='--', alpha=0.6)
plt.tight_layout()

# 保存图片
plot_path = os.path.join(out_dir, "AHP_weights_plot.png")
plt.savefig(plot_path, dpi=300)
plt.show()

print(f"  已生成权重分布图: {plot_path}")

```

问题二

"""

Problem-2 教师数字胜任力增值建模分析（优化版）

"""

```

import pandas as pd
import statsmodels.formula.api as smf
import matplotlib.pyplot as plt
import matplotlib
import os

```



```

# 字体设置，兼容中文
matplotlib.rcParams['font.family'] = 'Microsoft YaHei' # 或 SimHei
matplotlib.rcParams['axes.unicode_minus'] = False

# 1. 读取数据（修正：使用 read_excel 读取xlsx 文件）
data_path = r"C:\Users\LZC\Desktop\problem2_teacher_level_sample.xlsx"
df = pd.read_excel(data_path) # 移除 encoding 参数

# 2. 构造"增值"变量
df["VA"] = df["post_DC_score"] - df["pre_DC_score"]

# 3. 转换类别变量
df["gender"] = df["gender"].astype("category")
df["title_rank"] = df["title_rank"].astype("category")
df["region"] = df["region"].astype("category")
df["school"] = df["school"].astype("category")

# 4. 建模：MixedLM 优化器指定 + 回退 OLS（收敛失败时）
formula = "VA ~ gender + age + years_experience + title_rank + pre_DC_score"
try:
    model = smf.mixedlm(formula, df, groups=df["school"])
    result = model.fit(method="powell", maxiter=300) # 修正拼写错误为
"powell"
    print("\n 多层线性模型（MixedLM）结果：")
    print(result.summary())
except Exception as e:
    print(f"  MixedLM 收敛失败（{str(e)}），已改用普通 OLS 回归。")
    model = smf.ols(formula, df)
    result = model.fit()
    print(result.summary())

# 5. 输出每所学校的平均增值（+可视化）
school_va = df.groupby("school",
observed=True)["VA"].mean().sort_values(ascending=False)

```

```

plt.figure(figsize=(10, 6))
bars = plt.barh(school_va.index, school_va.values, color='skyblue')
plt.xlabel("平均增值 VA", fontsize=12)
plt.title("各高校教师平均数字胜任力增值", fontsize=14)
plt.gca().invert_yaxis()
plt.grid(axis='x', linestyle='--', alpha=0.6)

# 在条形图右侧显示数值
for bar in bars:
    width = bar.get_width()
    plt.text(width + 0.1, bar.get_y() + bar.get_height()/2, f'{width:.2f}',
va='center')

plt.tight_layout()

# 保存图表
plot_path = os.path.join(os.path.dirname(data_path), "school_va_barplot.png")
plt.savefig(plot_path, dpi=300)
plt.show()

print(f"\n✔ 可视化保存为: {plot_path}")

```

问题三

```

import pandas as pd
import statsmodels.formula.api as smf
from sklearn.ensemble import RandomForestRegressor
from sklearn.preprocessing import OneHotEncoder
from sklearn.compose import ColumnTransformer
from sklearn.pipeline import Pipeline
import pandas as pd
import statsmodels.formula.api as smf
from sklearn.ensemble import RandomForestRegressor
from sklearn.preprocessing import OneHotEncoder
from sklearn.compose import ColumnTransformer
from sklearn.pipeline import Pipeline

```

```

from sklearn.metrics import r2_score

# ===== 1) 读入数据 =====
df = pd.read_csv(r"D:\desktop\Desktop\problem2_teacher_level_sample.csv")
df["VA"] = df["post_DC_score"] - df["pre_DC_score"]

# ===== 2) 检查常数/重复列 =====
print("\n 检查常数列或重复列: ")
for col in df.columns:
    if df[col].nunique() <= 1:
        print(f" 变量 {col} 是常数列, 建议删除")

# ===== 3) 简化版 MixedLM =====
# 删除 training_participation, 避免与 annual_training_hours 共线
# 删除 years_experience, 避免与 age 高度相关
try:
    md = smf.mixedlm("VA ~ age + annual_training_hours +
sci_papers_last3yrs + \
                    digital_attitude + pre_DC_score +
is_double_first_class + C(region)",
                    df, groups=df["school"])
    result = md.fit(method="powell", maxiter=500)
    print("\n☑ MixedLM 模型已收敛: ")
    print(result.summary())
except Exception as e:
    print("✗ MixedLM 拟合失败: ", str(e))

# ===== 4) 随机森林特征重要度 =====
cat = ["gender", "title_rank", "region"] # region 用原始列参与 OneHot 编码
num = ["age", "annual_training_hours", "sci_papers_last3yrs",
       "digital_attitude", "pre_DC_score", "is_double_first_class"]

y = df["VA"]
X = df[cat + num]

```

```

# 编码 + 建模 pipeline
pre = ColumnTransformer([("cat", OneHotEncoder(drop="first"), cat)],
                        remainder="passthrough")

rf = RandomForestRegressor(n_estimators=500, random_state=0)
pipe = Pipeline([("prep", pre), ("model", rf)]).fit(X, y)

# 输出  $R^2$ 
print("\n    Random Forest In- sample  $R^2$  :", round(r2_score(y, pipe.predict(X)),
4))

# 特征重要度排序
feat_names = list(pipe["prep"].get_feature_names_out()) + num
importances = pipe["model"].feature_importances_

print("\n    Top- 10 特征重要度: ")
for name, imp in sorted(zip(feat_names, importances), key=lambda x:
-x[1]):10]:
    print(f'{name:<35} {imp:.4f}')

# ===== 5) 可视化 Top- 10 特征重要度 =====
import matplotlib.pyplot as plt
import matplotlib
matplotlib.rcParams['font.family'] = 'Microsoft YaHei' # 适配中文变量名
matplotlib.rcParams['axes.unicode_minus'] = False

# 提取前 10 个重要特征
top10 = sorted(zip(feat_names, importances), key=lambda x: -x[1]):10]
names, scores = zip(*top10)

plt.figure(figsize=(10, 6))
bars = plt.barh(range(len(names)), scores, color="skyblue")
plt.yticks(range(len(names)), names)
plt.xlabel("特征重要度", fontsize=12)
plt.title("随机森林: Top-10 特征重要度", fontsize=14)
plt.gca().invert_yaxis()

```

```

plt.grid(axis='x', linestyle='--', alpha=0.6)

# 显示数值
for i, bar in enumerate(bars):
    plt.text(bar.get_width() + 0.002, i, f'{bar.get_width():.4f}', va='center')

plt.tight_layout()

# 保存图像
plot_path = r"D:\desktop\Desktop\wentisan\rf_feature_importance_top10.png"
plt.savefig(plot_path, dpi=300)
plt.show()
print(f"\n  可视化图已保存为: {plot_path}")
# ===== 6) SHAP 可解释性分析 =====
import shap
import numpy as np

# 初始化解释器（基于已训练的随机森林模型）
explainer = shap.Explainer(pipe.named_steps["model"],
feature_names=pipe["prep"].get_feature_names_out())

# 获取预处理后的数据（注意：必须与训练时格式一致）
X_transformed = pipe.named_steps["prep"].transform(X)

# 计算 SHAP 值
shap_values = explainer(X_transformed)

# 绘制 summary_plot（横向条形图 + 颜色代表高低）
plt.figure()
shap.summary_plot(shap_values, features=X_transformed,
feature_names=explainer.feature_names, show=False)
shap_plot_path = r"D:\desktop\Desktop\wentisan\shap_summary_plot.png"
plt.savefig(shap_plot_path, dpi=300, bbox_inches="tight")
plt.show()
print(f"\n  SHAP summary_plot 已保存为: {shap_plot_path}")

```

```

from sklearn.metrics import r2_score

# ===== 1) 读入数据 =====
df = pd.read_csv(r"D:\desktop\Desktop\problem2_teacher_level_sample.csv")
df["VA"] = df["post_DC_score"] - df["pre_DC_score"]

# ===== 2) 检查常数/重复列 =====
print("\n 检查常数列或重复列: ")
for col in df.columns:
    if df[col].nunique() <= 1:
        print(f" 变量 {col} 是常数列, 建议删除")

# ===== 3) 简化版 MixedLM =====
# 删除 training_participation, 避免与 annual_training_hours 共线
# 删除 years_experience, 避免与 age 高度相关
try:
    md = smf.mixedlm("VA ~ age + annual_training_hours +
sci_papers_last3yrs + \
                    digital_attitude + pre_DC_score +
is_double_first_class + C(region)",
                    df, groups=df["school"])
    result = md.fit(method="powell", maxiter=500)
    print("\n☑ MixedLM 模型已收敛: ")
    print(result.summary())
except Exception as e:
    print("✗ MixedLM 拟合失败: ", str(e))

# ===== 4) 随机森林特征重要度 =====
cat = ["gender", "title_rank", "region"] # region 用原始列参与 OneHot 编码
num = ["age", "annual_training_hours", "sci_papers_last3yrs",
        "digital_attitude", "pre_DC_score", "is_double_first_class"]

y = df["VA"]
X = df[cat + num]

```

```

# 编码 + 建模 pipeline
pre = ColumnTransformer([("cat", OneHotEncoder(drop="first"), cat)],
                        remainder="passthrough")
rf = RandomForestRegressor(n_estimators=500, random_state=0)
pipe = Pipeline([("prep", pre), ("model", rf)]).fit(X, y)

# 输出 R2
print("\n    Random Forest In- sample R2 :", round(r2_score(y, pipe.predict(X)),
4))

# 特征重要度排序
feat_names = list(pipe["prep"].get_feature_names_out()) + num
importances = pipe["model"].feature_importances_

print("\n    Top- 10 特征重要度: ")
for name, imp in sorted(zip(feat_names, importances), key=lambda x:
-x[1])[10]:
    print(f'{name:<35} {imp:.4f}')
# ===== 5) 可视化 Top- 10 特征重要度 =====
import matplotlib.pyplot as plt
import matplotlib
matplotlib.rcParams['font.family'] = 'Microsoft YaHei' # 适配中文变量名
matplotlib.rcParams['axes.unicode_minus'] = False

# 提取前 10 个重要特征
top10 = sorted(zip(feat_names, importances), key=lambda x: -x[1])[10]
names, scores = zip(*top10)

plt.figure(figsize=(10, 6))
bars = plt.barh(range(len(names)), scores, color="skyblue")
plt.yticks(range(len(names)), names)
plt.xlabel("特征重要度", fontsize=12)
plt.title("随机森林: Top-10 特征重要度", fontsize=14)

```

```

plt.gca().invert_yaxis()
plt.grid(axis='x', linestyle='--', alpha=0.6)

# 显示数值
for i, bar in enumerate(bars):
    plt.text(bar.get_width() + 0.002, i, f'{bar.get_width():.4f}', va='center')

plt.tight_layout()

# 保存图像
plot_path = r"D:\desktop\Desktop\wentisan\rf_feature_importance_top10.png"
plt.savefig(plot_path, dpi=300)
plt.show()
print(f"\n  可视化图已保存为: {plot_path}")
# ===== 6) SHAP 可解释性分析 =====
import shap
import numpy as np

# 初始化解释器（基于已训练的随机森林模型）
explainer = shap.Explainer(pipe.named_steps["model"],
feature_names=pipe["prep"].get_feature_names_out())

# 获取预处理后的数据（注意：必须与训练时格式一致）
X_transformed = pipe.named_steps["prep"].transform(X)

# 计算 SHAP 值
shap_values = explainer(X_transformed)

# 绘制 summary_plot（横向条形图 + 颜色代表高低）
plt.figure()
shap.summary_plot(shap_values, features=X_transformed,
feature_names=explainer.feature_names, show=False)
shap_plot_path = r"D:\desktop\Desktop\wentisan\shap_summary_plot.png"
plt.savefig(shap_plot_path, dpi=300, bbox_inches="tight")
plt.show()

```



```
print(f"\n SHAP summary_plot 已保存为: {shap_plot_path}")
```