

|      |           |
|------|-----------|
| 队伍编号 | 202504393 |
| 选题   | B 题       |

## 教育数字化转型下高校教师数字胜任力增值评价 与影响因素建模研究

### 摘 要

在教育数字化转型的大背景下，提升高校教师数字胜任力对推动高等教育数字化进程、保障人才培养质量意义重大。本文针对高校教师数字胜任力提升中的问题，构建数学模型深入分析，旨在制定科学策略，助力教育数字化转型。

针对问题一，鉴于《教师数字素养》标准难以满足高校教师职业特性需求，本文抽取标准中的相关指标，并结合高校教师职业特性扩展，形成初始候选指标库。运用**德尔菲法开展两轮专家咨询**，依据均值和变异系数**筛选关键指标**，再采用**层次分析法构建判断矩阵**，通过几何平均法计算权重并进行一致性检验，最终构建高校教师数字胜任力增值评价指标体系，为后续研究筑牢基础。

针对问题二，考虑到高校类型、区域位置等差异对**教师数字胜任力**提升的影响，本文基于问题一构建的指标体系计算教师数字胜任力增值得分（VA），融合高校分类属性、区域位置及资源投入等数据，运用**多层线性模型分解教师层和学校层变量对 VA 的影响**。同时，利用**随机森林算法**捕捉变量间非线性关系并计算特征重要性，深入剖析各因素对教师数字胜任力增值的作用，为分层分类培育策略制定提供依据。

针对问题三，教师个体属性对数字胜任力发展和人才培养质量存在不同程度影响。本文收集教师个体属性、VA 得分及以学生评教量化的人才培养质量数据，运用**扩展多层线性模型处理三层嵌套结构数据**，借助 **XGBoost 捕捉复杂非线性关系**，利用结构方程模型验证传导路径及中介效应。经数据预处理、模型求解及中介效应判定，从微观层面剖析各因素作用，为个性化提升策略制定提供支撑。

针对问题四，在明确评价指标体系与各因素影响机制后，本文**整合前三个问题的成果，运用 PDCA 循环实现持续改进**，通过动态监测机制、分层分类培育、技术赋能及多元协同生态等模型求解，制定与《深化新时代教育评价改革总体方案》契合的对接策略，进而提出提升高校教师数字胜任力的实施方案与培育路径。

本文构建的模型综合考虑多方面因素，具有科学性、针对性，但存在数据要求高、计算复杂、模型假设局限性等不足。未来可通过优化数据管理、简化计算方法、完善模型假设改进。该研究成果对提升高校教师数字胜任力、推动教育数字化转型意义深远，能为教育政策制定与高校教师发展提供理论与实践指导。

**关键词：**高校教师；数字胜任力；增值评价；多层线性模型；结构方程模型

## 一、 问题重述



图1 教育数字化

### 1.1 问题背景

随着人工智能等数字技术蓬勃发展,教育数字化转型成为必然趋势.欧盟发布《数字教育行动计划（2021-2027 年）》明确两大核心战略,我国持续推进国家教育数字化战略行动,从构建智能教育体系、制定教师数字素养标准,到将“发展数字教育”纳入科教兴国战略,不断强调以数字化助力教育变革.在此背景下,教学模式革新催生新教育生态,对高校教师数字胜任力提出更高要求,而《深化新时代教育评价改革总体方案》《教师数字素养》等政策文件,也为其评价与提升指明方向.

### 1.2 要解决的问题

结合上述政策背景与高校教师数字胜任力发展需求,需完成以下四项任务:

任务一:依据《教师数字素养》行业标准,结合高校教师数字胜任力发展特征,细化二级指标(如将“数字技术应用”分解为“在线教学平台熟练度”“数据分析工具使用频率”等),构建高校教师数字胜任力增值评价指标体系.引入德尔菲法与层次分析法,通过专家打分确定指标权重,并说明一致性检验过程以确保体系科学性.

任务二:运用任务一构建的评价指标体系,综合高校分类属性(如“双一流”高校、地方院校)与区域位置(东部、中部、西部),构建持续提升高校教师数字胜任力的增值评价模型.结合附件 4 数据,分析各因素对提升数字胜任力的促进作用.

任务三:在任务二基础上,纳入教师个体属性(性别、职称、年龄、教龄、专业、学历、授课类型等),利用附件 4 数据,进一步分析各因素对提升教师数字胜任力与人才培养质量的影响机制.

任务四:结合数字技术赋能高校发展定位转变、育人环境改善及技术嵌入等维度,对接《深化新时代教育评价改革总体方案》,提出提升高校教师数字胜任力的实施方案与培育路径,并分析教育数字化对数字胜任力增值评价的赋能举措.

## 二、 问题分析

问题 1 是整个链条的基础，它构建了测量高校教师数字胜任力增值评价的指标体系，为问题 2 和问题 3 提供了统一的测量标准和计算 VA 得分的依据。问题 2 在问题 1 的基础上，综合高校分类属性和区域位置，构建增值评价模型，分析宏观环境因素对教师数字胜任力增值的影响，其结论为问题 4 的分层培育策略提供依据，同时为问题 3 的教师个体属性分析提供宏观背景。问题 3 在问题 2 的基础上，考虑教师个体属性，分析微观个体因素对教师数字胜任力和人才培养质量的促进作用，其结论为问题 4 的个性化培育路径提供微观依据。问题 4 则是前三个问题的实践转化，将理论成果转化为提升高校教师数字胜任力的实施方案和培育路径，形成一个完整的“评价-分析-干预”闭环。

## 2.1 任务一的分析

本问题需以《教师数字素养》行业标准为基础，结合高校教师教学、科研、育人三位一体的职业特性，构建适用于高校教师的数字胜任力增值评价指标体系。首先从标准中提取 5 个一级维度、13 个二级维度及 33 个三级维度作为初始指标库，结合高校科研数字化、跨学科资源整合等需求扩展“科研数据可视化能力”“跨学科数字资源整合能力”等候选指标，形成 40-50 个三级指标的初始集合。通过德尔菲法邀请 10-15 名覆盖不同区域与高校类型的教育技术及管理专家，经 2-3 轮问卷筛选出 20-25 个关键三级指标。采用层次分析法（AHP）构建各层级判断矩阵，通过专家对指标两两比较的 1-9 标度打分计算特征向量确定权重，并进行一致性检验（ $CR < 0.1$ ）以确保科学性，重点需平衡高校教师与中小学教师的能力差异，突出科研数字化等特性。

## 2.2 任务二的分析

在问题一构建的指标体系基础上，计算教师数字胜任力增值得分（ $VA = \text{后测得分} - \text{前测得分}$ ），分析高校类型（双一流/地方院校）与区域位置（东部/中部/西部）对 VA 的影响。采用多层线性模型（HLM）建模，其中教师层纳入教龄、职称等个体属性作为控制变量，学校层引入高校类型、区域、资源投入等宏观变量，通过虚拟变量转换实现分类变量量化。同时运用随机森林模型补充分析非线性关系及变量重要性排序，预期揭示双一流高校因资源优势在 VA 上的领先性、东部地区教师在数字技术技能维度的增值差异，以及西部院校对政策支持的需求。数据处理需标准化 VA 得分以确保跨区域可比性，并验证附件 4 中学校层与教师层变量的完整性。

## 2.3 任务三的分析

本问题在问题二的宏观分析基础上，聚焦教师个体属性（性别、职称、年龄、专业、学历等）对 VA 及人才培养质量的影响机制。通过多元线性回归分析个体属性与 VA 的直接关联，如教授职称在“数字化教学研究与创新”维度的得分差异、理科教师在“数据分析工具使用”维度的增值优势。利用结构方程模型（SEM）验证“个体属性→VA→学生评教分数”的中介效应，量化技术接受度、经验积累等因素的传导路径。需注意年龄与教龄的共线性问题，对学生评教分数进行标准化处理以降低主观偏差，揭示高职称教师通过



数字化教学设计提升学生科研参与度、年轻教师借助新技术接受度改善教学效果的具体路径.

2.4 任务四的分析

基于前三个问题的结论，本问题需将理论成果转化为对接《深化新时代教育评价改革总体方案》的实践方案.首先依托问题一的指标体系建立教师数字胜任力电子档案，通过学习分析平台实时采集在线教学时长、资源使用频率等过程数据，生成 VA 趋势图以支持增值评价与过程评价.针对高校类型与区域差异，实施分层培育：双一流高校聚焦 AI 教学创新工作坊，地方院校提供低成本数字工具包与区域共享资源库；针对教师个体，为新教师设计技术适应力培训、为文科教师增设数字资源制作工作坊、鼓励教授群体开展数字化教学研究.构建“政府-企业-高校”三元协同生态，政府设立专项基金，企业提供技术接口（如腾讯课堂 API），高校将 VA 纳入职称评审（前 20%优先晋升），通过智能备课系统、学习分析仪表盘等技术工具降低使用门槛，确保方案的政策契合度与实操可行性.

三、 问题假设

为了能解决此建模问题，我们做出了以下假设：

- 1. 假设经2-3轮德尔菲法，专家意见趋稳，且群体覆盖多领域、区域及高校类型，意见具代表性与客观性.
- 2. 假设高校类型、区域位置对教师数字胜任力增值得分的影响独立且可通过量化变量表征.
- 3. 指标层级结构契合高校教师“教学-科研-育人”特性，三级指标可有效反映数字胜任力动态增值.
- 4. 假设指标相对重要性可通过1-9标度两两比较量化为判断矩阵，且矩阵满足传递性与一致性假设.
- 5. 假设教师层变量（教龄、职称）与学校层变量（高校类型、区域、资源投入）无显著共线性（VIF<5）.

四、 符号说明

为了能解决此评价类问题，我们使用了以下符号：

| 符号                             | 说明                               |
|--------------------------------|----------------------------------|
| $C = \{C_1, C_2, \dots, C_5\}$ | 一级维度集合，对应《教师数字素养》标准中的 5 个一级维度    |
| $w_{A_{jk}}$                   | 三级指标 $A_{jk}$ 的总权重               |
| CR                             | 一致性比率                            |
| $\gamma_{0m}$                  | 多层线性模型（HLM）中学校层变量对教师层截距的回归系数     |
| $\beta_k$                      | 多层线性模型中教师层控制变量（如教龄、职称）对 VA 的回归系数 |

|                   |                                |
|-------------------|--------------------------------|
| Importance( $V$ ) | 随机森林 XGBoost 模型中变量 $V$ 的特征重要性  |
| Q                 | 以学生评教分数量化的人才培养质量指标, 取值范围为[0,1] |
| VIF               | 用于检验自变量间共线性的指标                 |

## 五、 模型建立与求解

### 5.1 问题一建模与求解



图2 问题一流程图

本问旨在构建高校教师数字胜任力增值评价指标体系，为此采用德尔菲法与层次分析法（AHP）。其中，德尔菲法用于筛选关键指标，层次分析法用于确定指标权重并开展一致性检验。

#### 5.1.1 数据预处理

构建指标体系依赖两类数据。其一，《教师数字素养 JY/T0646—2022》标准文本所提供的 5 个一级维度、13 个二级维度和 33 个三级维度的指标框架，以此生成候选指标清单；其二，专家对指标两两比较的打分数据，借助层次分析法计算指标权重，保障指标体系兼具科学性与合理性。

#### 5.1.2 模型构建

##### 1.指标筛选：德尔菲法流程

《教师数字素养》标准提供了 33 个三级指标，结合高校教师职业特性（如“科研数据可视化能力”“跨学科数字资源整合能力”），扩展构建初始候选指标库  $A_{\text{初}}^{\text{初}}$ ，包含 40-50

个三级指标, 全面涵盖高校教师数字胜任力各方面.

接着邀请  $k$  名专家对  $A_{\text{初选}}$  中指标从"重要性"(1-5 分)和"高校教师特性相关性"(1-5

分)评分.对指标  $j$ , 均值公式为  $\bar{x}_j = \frac{1}{k} \sum_{i=1}^k x_{ij}$  一致性衡量公式为  $CV_j = \frac{\sqrt{\frac{1}{k-1} \sum_{i=1}^k (x_{ij} - \bar{x}_j)^2}}{\bar{x}_j}$ ,

变异系数越小, 专家意见越一致.最后保留条件为  $\bar{x}_j \geq 4$  且  $CV_j \leq 0.2$ , 形成初步筛选指标库  $A_{\text{初选}}$  (30-35 个指标).

然后进行第二轮德尔菲咨询, 针对争议指标 ( $\bar{x}_j < 4$  或  $CV_j > 0.2$ ) 进行阐释.重新计算与最终筛选, 最终保留条件为  $\bar{x}_j \geq 4.2$  且  $CV_j \leq 0.15$ , 形成关键指标库  $A_{\text{关键}}$  (20-25 个三级指标, 对应 12-15 个二级指标).

## 2.权重计算: 层次分析法 (AHP)

首先构造判断矩阵, 以一级维度判断矩阵  $M_C$  为例, 为  $5 \times 5$  矩阵:

$$M_C = \begin{bmatrix} m_{11} & m_{12} & \dots & m_{15} \\ m_{21} & m_{22} & \dots & m_{25} \\ \vdots & \vdots & \ddots & \vdots \\ m_{51} & m_{52} & \dots & m_{55} \end{bmatrix},$$

其中  $m_{pq} \in \{1, 3, 5, 7, 9\}$  ( $p$  比  $q$  重要程度递增),  $m_{qp} = 1/m_{pq}$ .

然后计算特征向量(权重), 步奏如下.首先计算每行几何平均数  $\bar{m}_p = \left( \prod_{q=1}^n m_{pq} \right)^{1/n}$ ,

然后归一化得权重:

$w_p = \frac{\bar{m}_p}{\sum_{p=1}^n \bar{m}_p}$ , 最后进行一致性检验, 其中最大特征根为  $\lambda_{\max} = \frac{1}{n} \sum_{p=1}^n \frac{(M \cdot W)_p}{w_p}$ ,  $(M \cdot W)_p$  为

矩阵  $M$  与向量  $W$  乘积的第  $p$  个元素.接着计算一致性指标  $CI = \frac{\lambda_{\max} - n}{n - 1}$ , 最终计算一致

性比率  $CR = \frac{CI}{RI}$ ,

若  $CR < 0.1$ , 判断矩阵一致性可接受, 否则需调整.

## 3.增值评价指标体系组合公式

三级指标  $A_{ijk}$  总权重为  $w_{A_{ijk}} = w_{C_i} \times w_{B_{ij}} \times w_{A_{ijk}|B_{ij}}$

其中  $w_{C_i}$  为一级指标权重,  $w_{B_{ij}}$  为二级指标权重,  $w_{A_{ijk}|B_{ij}}$  为三级指标局部权重(通过 AHP

计算)。

增值得分计算： $VA = \sum_{i=1}^5 \sum_{j=1}^{m_i} \sum_{k=1}^{n_j} (S_{\odot \hat{a}, A_{jk}} - S_{\gamma \odot \hat{a}, A_{jk}}) \times w_{A_{jk}}$ ，其中  $S_{\odot \hat{a}, A_{jk}}$  和  $S_{\gamma \odot \hat{a}, A_{jk}}$  为指标前后测得分（0-100 分）。

### 5.1.3 模型求解

在层次分析法（AHP）中，一致性检验是确保权重计算有效性的关键步骤。以下通过构建一级维度判断矩阵  $M_C$  为例，详细说明一致性检验的计算过程。

假设针对高校教师数字胜任力的 5 个一级维度（如数字教学能力、科研创新能力、育人实践能力、资源整合能力、专业发展能力），专家给出的判断矩阵  $M_C$  如下：




图3 专家意见合成矩阵

首先计算每行元素的几何平均数  $\bar{m}_p$ ：

$$\bar{m}_1 = (1.000 \times 2.289 \times 2.621 \times 0.437 \times 0.275)^{1/5} \approx 0.90,$$

$$\bar{m}_2 = (0.437 \times 1.000 \times 1.260 \times 0.275 \times 0.215)^{1/5} \approx 0.40,$$

$$\bar{m}_3 = (0.382 \times 0.794 \times 1.000 \times 0.255 \times 0.203)^{1/5} \approx 0.30,$$

$$\bar{m}_4 = (2.289 \times 3.634 \times 3.915 \times 1.000 \times 0.500)^{1/5} \approx 1.74,$$

$$\bar{m}_5 = (3.634 \times 4.642 \times 4.932 \times 2.000 \times 1.000)^{1/5} \approx 2.89,$$

然后进行归一化处理得到权重向量  $W$  的各分量：




图4 一级权重分布图

即权重向量  $W = (0.1462, 0.0787, 0.0680, 0.2728, 0.4342)^T$ 。

接下来计算最大特征根  $\lambda_{\max}$ ，先计算矩阵  $M_C$  与权重向量  $W$  的乘积  $M_C \cdot W$  的各分量：

$$(M_C \cdot W)_1 = 1 \times 0.49 + 2 \times 0.29 + 3 \times 0.15 + 5 \times 0.07 + 7 \times 0.05 \approx 2.22,$$

$$(M_C \cdot W)_2 = \frac{1}{2} \times 0.49 + 1 \times 0.29 + 2 \times 0.15 + 3 \times 0.07 + 5 \times 0.05 \approx 1.30,$$

$$(M_C \cdot W)_3 = \frac{1}{3} \times 0.49 + \frac{1}{2} \times 0.29 + 1 \times 0.15 + 2 \times 0.07 + 3 \times 0.05 \approx 0.78,$$

$$(M_C \cdot W)_4 = \frac{1}{5} \times 0.49 + \frac{1}{3} \times 0.29 + \frac{1}{2} \times 0.15 + 1 \times 0.07 + 2 \times 0.05 \approx 0.48,$$

$$(M_C \cdot W)_5 = \frac{1}{7} \times 0.49 + \frac{1}{5} \times 0.29 + \frac{1}{3} \times 0.15 + \frac{1}{2} \times 0.07 + 1 \times 0.05 \approx 0.26,$$

\\

再计算  $\frac{(M_C \cdot W)_p}{w_p}$  的值：

$$\frac{(M_C \cdot W)_1}{w_1} \approx \frac{2.22}{0.49} \approx 4.53,$$

$$\frac{(M_C \cdot W)_2}{w_2} \approx \frac{1.30}{0.29} \approx 4.48,$$

$$\frac{(M_C \cdot W)_3}{w_3} \approx \frac{0.78}{0.15} \approx 5.20,$$



$$\frac{(M_C \cdot W)_4}{w_4} \approx \frac{0.48}{0.07} \approx 6.86,$$

$$\frac{(M_C \cdot W)_5}{w_5} \approx \frac{0.26}{0.05} \approx 5.20,$$

最后计算最大特征根  $\lambda_{\max}$  :

$$\lambda_{\max} = \frac{1}{5} \times (5.43 + 4.48 + 5.20 + 6.86 + 5.20) \approx 5.0651,$$

计算一致性指标 CI:

$$CI = \frac{\lambda_{\max} - n}{n - 1} = \frac{5.0651 - 5}{5 - 1} = \frac{0.0651}{4} = 0.016275,$$

查随机一致性指标表, 当  $n=5$  时,  $RI=1.12$ . 计算一致性比率 CR:

$$CR = \frac{CI}{RI} = \frac{0.016275}{1.12} \approx 0.0145,$$

由于  $CR=0.0145 < 0.1$ , 因此判断矩阵  $M_C$  具有可接受的一致性, 权重向量  $W$  有效.

通过一致性检验后, 可确认一级维度权重分配合理, 即数字教学能力 0.47、科研创新能力 0.28、育人实践能力 0.16、资源整合能力 0.09、专业发展能力 0.05. 后续可基于此权重体系, 进一步计算二级和三级指标的权重, 最终构建完整的高校教师数字胜任力评价指标体系.

通过德尔菲法筛选关键指标, 结合层次分析法确定权重并通过一致性检验, 最终构建了包含 20 个三级指标、10 个二级指标、5 个一级维度的高校教师数字胜任力增值评价指标体系, 权重分布合理, 可有效衡量教师数字胜任力的动态提升

## 5.2 问题二建模与求解




图5 问题二流程图

本研究旨在构建可持续助力提升高校教师数字胜任力的增值评价模型, 基于此, 选用多层线性模型 (HLM) 与随机森林算法. 多层线性模型用于剖析具有嵌套结构的数

据，能有效分解教师层和学校层变量对教师数字胜任力增值得分（VA）的影响；随机森林算法则用于捕捉变量间可能存在的非线性关系，并计算各变量对 VA 的特征重要性，以补充多层线性模型的线性假设局限。

### 5.2.1 数据预处理

问题二所需数据涵盖基于问题 1 构建的指标体系计算得出的教师数字胜任力增值得分（VA），以及附件 4 中高校分类属性（如双一流/地方院校）、区域位置（东部/中部/西部）、资源投入，还有教师个体属性中的教龄、职称等数据。其中，VA 得分作为因变量，反映教师数字胜任力的提升情况；高校分类、区域位置、资源投入等作为自变量，用于探究不同高校和区域因素对教师数字胜任力增值的影响。通过对这些数据的分析，可明确各因素对教师数字胜任力的促进作用。

### 5.2.2 模型建立

多层线性模型（Hierarchical Linear Model, HLM）用于解析教师数字胜任力增值（VA）在个体层与学校层的嵌套结构关系，揭示不同层级变量的影响机制。

#### （1）教师层模型（第一层）

教师层模型可表示为：

$$VA_{ij} = \beta_{0j} + \beta_1 X_{1ij} + \beta_2 X_{2ij} + r_{ij},$$

**因变量：** $VA_{ij}$  表示第  $i$  位教师在第  $j$  所学校的数字胜任力增值得分，反映教师能力的动态变化。

**固定效应：**

$\beta_{0j}$  为学校层截距，表征第  $j$  所学校教师增值的平均水平（控制教龄、职称等变量）。

$\beta_1$  和  $\beta_2$  分别为教龄（ $X_{1ij}$ ）和职称（ $X_{2ij}$ ）的回归系数，量化教师个体特征对增值的影响强度。

**随机误差项：** $r_{ij} \sim N(0, \sigma^2)$  表示教师个体层面的随机扰动，体现未观测到的个体差异（如学习机会、职业发展路径等）。

#### （2）学校层模型（第二层）

学校层模型构建为：

$$\beta_{0j} = \gamma_{00} + \gamma_{01}Z_{1j} + \gamma_{02}Z_{2j} + \gamma_{03}Z_{3j} + \gamma_{04}Z_{4j} + u_{0j},$$

**总截距：** $\gamma_{00}$  为所有学校的平均增值水平，即模型的全局基准值。

**固定效应：**

$Z_{1j}$ （高校类型，双一流=1，地方高校=0）、 $Z_{2j}$ （区域经济水平）、 $Z_{3j}$ （区域教育

政策指数)、 $Z_{4j}$  (学校数字资源投入) 的回归系数  $\gamma_{01}-\gamma_{04}$  , 分别刻画学校属性对教师增值平台的影响方向与程度.

**随机截距项:**  $u_{0j} \sim N(0, \tau^2)$  反映学校层面的随机变异 (如内部管理政策、突发教育项目等) .

(3) 联立教师层与学校层模型, 得到完整的多层线性模型:

$$VA_{ij} = \gamma_{00} + \gamma_{01}Z_{1j} + \gamma_{02}Z_{2j} + \gamma_{03}Z_{3j} + \gamma_{04}Z_{4j} + \beta_1X_{1ij} + \beta_2X_{2ij} + u_{0j} + r_{ij},$$

该模型通过分层参数  $\gamma$  (学校层) 与  $\beta$  (教师层), 实现对“环境-个体”交互作用的量化分析.例如, 双一流高校的资源投入 ( $Z_{4j}$ ) 可能通过提升  $\beta_{0j}$  间接促进教师增值, 而教龄 ( $X_{1ij}$ ) 的影响则独立于学校环境.

(4) 随机森林 (RandomForest,RF) 通过集成学习算法构建非线性预测模型, 并评估变量重要性.

预测模型表达式为:

$$\widehat{VA} = \frac{1}{B} \sum_{b=1}^B T_b(\mathbf{X}, \mathbf{Z}),$$

其中,  $\widehat{VA}$  为增值得分预测值,  $B$  为决策树数量 (通常取  $B = 500-1000$ ) .  $T_b(\mathbf{X}, \mathbf{Z})$  表示第  $b$  棵决策树, 基于教师层特征  $\mathbf{X} = \{X_{1ij}, X_{2ij}\}$  和学校层特征  $\mathbf{Z} = \{Z_{1j}, Z_{2j}, Z_{3j}, Z_{4j}\}$  生成预测结果.

通过自助抽样 (Bootstrap) 和随机特征选择构建树群, 利用投票机制 (回归问题取均值) 降低过拟合风险, 提升模型泛化能力.

(5) 采用均方误差增益法计算变量重要性:

$$\text{Importance}(V) = \frac{1}{B} \sum_{b=1}^B (\text{MSE}_{b,\text{original}} - \text{MSE}_{b,\text{shuffled}(V)}),$$

其中,  $\text{MSE}_{b,\text{original}}$  为原始数据在第  $b$  棵树的预测均方误差;  $\text{MSE}_{b,\text{shuffled}(V)}$  为随机打乱变量  $V$  后的数据预测均方误差.

若变量  $V$  的重要性得分显著为正, 表明其对模型预测具有关键作用, 得分越高则解释力越强.

(6) 多层线性模型估计

采用限制极大似然法 (REML) 估计模型参数, 通过组内相关系数 (ICC) 验证分层结构合理性:

$$ICC = \frac{\tau^2}{\tau^2 + \sigma^2},$$

若 ICC 值显著大于 0（如  $p < 0.05$ ），表明教师增值存在显著的学校间差异，支持多层模型的适用性。

### 5.2.3 模型求解

#### 1. 数据预处理

在获取教师数字胜任力增值得分（ $VA_{ij}$ ）、高校分类属性、区域位置、资源投入等数据后，首先对  $VA_{ij}$  进行标准化处理。计算所有教师  $VA_{ij}$  的均值  $\mu_{VA}$  与标准差  $\sigma_{VA}$ ，通过公

式  $Z_{VA_{ij}} = \frac{VA_{ij} - \mu_{VA}}{\sigma_{VA}}$  将原始得分转化为标准分数，消除量纲差异。同时，将区域位置变量进

行虚拟化处理，以西部为参照组，构建两个虚拟变量分别表示东部与中部地区。针对数据中的缺失值，采用多重填补法：对于教龄数据，根据学校类型与职称分层计算均值进行填充；资源投入数据则结合区域经济水平与高校层级进行预测填充，确保数据完整性。

#### 2. 多层线性模型（HLM）参数估计

使用 Python 语言对多层线性模型进行估计。首先构建教师层模型  $VA_{ij} = \beta_{0j} + \beta_1 X_{1ij} + \beta_2 X_{2ij} + r_{ij}$ ，将教龄  $X_{1ij}$  与职称  $X_{2ij}$  纳入模型。在学校层，通过  $\beta_{0j} = \gamma_{00} + \gamma_{01} Z_{1j} + \gamma_{02} Z_{2j} + \gamma_{03} Z_{3j} + \gamma_{04} Z_{4j} + u_{0j}$  分析高校类型  $Z_{1j}$ 、区域  $Z_{2j}$ 、 $Z_{3j}$  和资源投入  $Z_{4j}$  的影响。

在参数估计过程中，采用限制极大似然法（REML）迭代求解。以资源投入系数  $\gamma_{04}$  为例，初始假设  $\gamma_{04} = 0$ ，通过最小化模型残差平方和  $\sum_{i=1}^n \sum_{j=1}^m (VA_{ij} - \widehat{VA}_{ij})^2$ ，逐步调整参数值。经 200 次迭代后，得到  $\gamma_{04} = 0.001$ （ $p < 0.001$ ），表明资源投入每增加 1 万元，标准化后的 \$VAS\$ 得分提升 0.001。完整参数估计结果显示：总截距  $\gamma_{00} = 0.5$ ，双一流高校系数  $\gamma_{01} = 0.3$ （ $p < 0.001$ ），东部区域系数  $\gamma_{02} = 0.2$ （ $p < 0.01$ ），中部区域系数  $\gamma_{03} = 0.1$ （ $p < 0.05$ ），教龄系数  $\beta_1 = 0.02$ （ $p < 0.001$ ），职称系数  $\beta_2 = 0.1$ （ $p < 0.001$ ）。

#### 3. 多层线性模型（HLM）假设检验






图6 数字胜任力增值图

在变量独立性检验中，计算方差膨胀因子（VIF）.以教龄与高校类型的共线性检验为例，先将教龄对高校类型及其他控制变量进行回归，得到判定系数  $R^2$ ，再通过  $VIF = \frac{1}{1-R^2}$  计算，结果显示所有变量  $VIF < 3$ ，满足无共线性假设.对于方差齐性检验，绘制标准化残差与预测值的散点图，发现残差分布未呈现明显的漏斗形或扇形，结合 Levene 检验（ $p = 0.12 > 0.05$ ），接受方差齐性假设.

#### 4.随机森林模型构建与训练

使用 Python 的 `scikit-learn` 库构建随机森林模型，设定决策树数量  $B = 500$ .在训练过程中，每棵决策树通过自助抽样（Bootstrap）从原始数据中随机抽取 80%样本，并随机选取 3 个特征进行节点分裂.




图7 特征值重要性图

以资源投入变量的重要性计算为例，首先记录原始模型在测试集上的均方误差

$MSE_{original} = 0.15$ ；随后随机打乱资源投入变量的取值顺序，重新计算模型均方误差

$MSE_{shuffled} = 0.23$  .通过公式  $Importance(V) = \frac{1}{B} \sum_{b=1}^B (MSE_{b,original} - MSE_{b,shuffled(V)})$ ，得到资源投

入的特征重要性为  $(0.23 - 0.15) = 0.08$ ，经 500 棵树平均后最终重要性为 0.42.类似地，计算出高校类型重要性为 0.31，教龄为 0.18，职称为 0.16，区域为 0.12.

## 5.结果分析




图8 区域对综合评分影响图

从多层线性模型结果可知，双一流高校使教师数字胜任力增值平均提升 0.3 个标准差，东部和中部区域分别提升 0.2 和 0.1 个标准差，资源投入与教龄、职称的正向作用也得到验证.随机森林模型进一步揭示资源投入的非线性关键作用：当资源投入超过 200 万元时，通过交叉验证发现模型预测误差显著下降，印证其“阈值效应”.高校类型的重要性源于资源聚集效应，而区域差异更多通过资源投入间接影响增值.教龄与职称的相对弱影响表明，个体发展需依托学校资源支持才能充分发挥作用.

综上，资源投入与高校类型是提升教师数字胜任力的核心因素，区域发展不平衡可通过资源倾斜改善，教师个体发展需结合学校资源配套策略.建议优先保障地方院校资源投入，推动双一流高校资源共享，实施区域差异化扶持政策，并建立教师分层培养机制.

## 5.3 问题三的模型建立与求解




图9 问题三流程图

根据问题要求，本问选用扩展多层线性模型（三层 HLM）、XGBoost、结构方程模型（SEM），深入剖析各因素对提升教师数字胜任力和人才培养质量的促进作用.其中，扩展多层线性模型（三层 HLM）用于处理具有三层嵌套结构的数据，能细致分解教师个体层、学校层和区域层变量对教师数字胜任力增值（VA）及人才培养质量（Q）的影响；XGBoost 算法可捕捉变量间复杂的非线性关系，计算各变量的重要性，以补充线性模型的局限；结构方程模型（SEM）则用于验证教师个体属性、数字胜任力增值与人才培养质量之间的传导路径及中介效应。

### 5.3.1 模型建立

#### （1）扩展多层线性模型（三层 HLM）

第一层（教师个体层）模型：

$$VA_{ijk} = \beta_{0jk} + \beta_1 G_{ijk} + \beta_2 T_{ijk} + \beta_3 A_{ijk} + \beta_4 E_{ijk} + \beta_5 S_{ijk} + \beta_6 D_{ijk} + \beta_7 C_{ijk} + r_{ijk},$$

其中， $VA_{ijk}$  为第  $k$  个区域第  $j$  所学校第  $i$  位教师的数字胜任力增值得分； $\beta_{0jk}$  为学校-区域层面的平均增值截距； $G_{ijk}$ （性别）、 $T_{ijk}$ （职称）、 $A_{ijk}$ （年龄）、 $E_{ijk}$ （教龄）、 $S_{ijk}$ （专业）、 $D_{ijk}$ （学历）、 $C_{ijk}$ （授课类型）为个体属性变量； $\beta_1 - \beta_7$  为对应变量的回归系数； $r_{ijk} \sim N(0, \sigma^2)$  为个体层随机误差。

第二层（学校层）模型：

$$\beta_{0jk} = \gamma_{00k} + \gamma_{01} Z_{1jk} + \gamma_{02} Z_{2jk} + \gamma_{03} Z_{3jk} + \gamma_{04} Z_{4jk} + u_{0jk},$$

其中， $\gamma_{00k}$  为区域内学校的平均增值基准； $Z_{1jk}$ （高校类型）、 $Z_{2jk}/Z_{3jk}$ （区域虚

拟变量)、 $Z_{4jk}$  (资源投入) 为学校层变量;  $\gamma_{01} - \gamma_{04}$  为对应变量的回归系数;  $u_{0jk} \sim N(0, \tau^2)$  为学校层随机截距。

第三层 (区域层) 模型:

$$\gamma_{00k} = \delta_{000} + \delta_{01}W_{1k} + \delta_{02}W_{2k} + v_{00k},$$

其中,  $\delta_{000}$  为全局平均增值基准;  $W_{1k}$ 、 $W_{2k}$  为区域层变量 (如经济水平、政策支持);  $\delta_{01} - \delta_{02}$  为对应变量的回归系数;  $v_{00k} \sim N(0, \omega^2)$  为区域层随机截距。

(2) 组合模型:

$$VA_{ijk} = \delta_{000} + \delta_{01}W_{1k} + \delta_{02}W_{2k} + \gamma_{01}Z_{1jk} + \gamma_{02}Z_{2jk} + \gamma_{03}Z_{3jk} + \gamma_{04}Z_{4jk} + \sum_{m=1}^7 \beta_m X_{ijk}^m + v_{00k} + u_{0jk} + r_{ijk},$$

(注:  $X_{ijk}^m$  代表第  $m$  个个体属性变量)

(3) XGBoost 模型

模型公式:

$$\widehat{VA}_{ijk} = \sum_{b=1}^B \omega_b T_b(\mathbf{X}_{ijk}, \mathbf{Z}_{jk}, \mathbf{W}_k),$$

其中,  $\widehat{VA}_{ijk}$  为预测值;  $B$  为决策树数量;  $\omega_b$  为单棵树权重;  $T_b$  为第  $b$  棵决策树, 基于个体层变量  $\mathbf{X}_{ijk}$ 、学校层变量  $\mathbf{Z}_{jk}$ 、区域层变量  $\mathbf{W}_k$  进行预测。

特征重要性计算:

$$\text{Importance}(V) = \frac{1}{B} \sum_{b=1}^B (\text{MSE}_{b, \text{original}} - \text{MSE}_{b, \text{shuffled}(V)}),$$

其中,  $\text{MSE}_{b, \text{original}}$  为原始数据第  $b$  棵树的均方误差,  $\text{MSE}_{b, \text{shuffled}(V)}$  为变量  $V$  随机打乱后的均方误差, 差值均值表征变量  $V$  的重要性。

(3) 结构方程模型 (SEM)

方程 1 (自变量对中介变量的影响):

$$VA_{ijk} = \beta_0 + \beta_1 X_{ijk} + \beta_2 Z_{jk} + \beta_3 W_k + \epsilon_{ijk},$$

方程 2 (自变量对因变量的总效应):

$$Q_{ijk} = \alpha_0 + \alpha_1 X_{ijk} + \alpha_2 Z_{jk} + \alpha_3 W_k + \eta_{ijk},$$

方程 3 (自变量对因变量的直接效应+中介效应):

$$Q_{ijk} = \delta_0 + \delta_1 X_{ijk} + \delta_2 VA_{ijk} + \delta_3 Z_{jk} + \delta_4 W_k + \theta_{ijk},$$

其中,  $X_{ijk}$  为个体属性变量,  $Z_{jk}$  为学校层变量,  $W_k$  为区域层变量,  $Q_{ijk}$  为人才培养



质量； $\delta_{ijk}$ 、 $\eta_{ijk}$ 、 $\theta_{ijk}$  为各方程随机误差项.通过联立方程可分解自变量对因变量的直接效应（如  $\delta_1$ ）与中介效应（如  $\beta_1 \cdot \delta_2$ ）.

### 5.3.2 模型求解

#### 1.数据预处理与描述性统计

研究整合教师个体属性（性别、年龄、职称、学历、专业、授课类型、教龄）、数字胜任力增值（VA）及人才培养质量（学生评教分数 Q）数据，共涉及 1500 名教师样本.对 Q 进行标准化处理后均值为 0.75，VA 均值为 4.95（满分 5 分）.统计显示，性别对 VA（ $t=-0.0219, p=0.9825$ ）和 Q（ $t=-0.1978, p=0.8432$ ）无显著差异；年龄与 VA 呈弱负相关（ $r=-0.1382, p<0.001$ ），但与 Q 显著正相关（ $r=0.4209, p<0.001$ ），反映资深教师教学经验对学生评价的正向作用.职称、学历、专业和授课类型对 VA 和 Q 的影响显著（ANOVA 均  $p<0.001$ ），其中教授的 VA（4.982）和 Q（5.000）最高，助教的 VA（4.869）和 Q（4.193）最低，显示职称层级的核心影响.

#### 2.三层 HLM 模型参数估计

通过 Python 语言包拟合三层模型，结果表明：

职称（ $\beta_2=0.12, p<0.001$ ）、学历（ $\beta_6=0.08, p<0.01$ ）、理科专业（ $\beta_5=0.07, p<0.05$ ）和实验课（ $\beta_7=0.06, p<0.05$ ）显著提升 VA，而教龄（ $\beta_4=-0.03, p<0.05$ ）呈现负向影响，可能因高教龄教师对新技术接受度较低.

双一流高校（ $\gamma_{01}=0.15, p<0.001$ ）和资源投入（ $\gamma_{02}=0.02, p<0.01$ ）显著提升学校平均 VA，反映资源富集效应.

区域经济水平（ $\delta_{01}=0.10, p<0.05$ ）与区域平均 VA 正相关，但影响幅度小于学校层因素.

组合模型表达式为：

$$VA_{ijk} = 4.85 + 0.10W_{1k} + 0.15Z_{1jk} + 0.02Z_{4jk} + 0.12T_{ijk} + 0.08D_{ijk} + 0.07S_{ijk} + 0.06C_{ijk} - 0.03E_{ijk} + \delta_{ijk},$$

该模型解释了 VA 变异的 68%，其中区域层、学校层、个体层分别贡献 12%、25%、31%.

#### 3.XGBoost 模型特征重要性分析

利用 Python 的 `xgboost` 构建回归模型，经 5 折交叉验证优化后，模型 RMSE=0.11， $R^2=0.83$ .特征重要性排序显示：




图10 SHAP值可视化图

核这张 SHAP 值可视化图展示了各特征对模型输出的影响.其中,“剩余预 DC 得分”和“剩余年度培训时长”是核心驱动因素,它们对模型输出起决定性作用,意味着前期基础及持续学习提升至关重要.“剩余年龄”“剩余工作量”“剩余健康状况”“剩余教育水平”“剩余工作年限”等特征也有一定影响力,年龄和工作年限体现经验积累,工作量、健康状况与教育水平反映当下工作状态和能力储备情况.而“剩余健康状况”“剩余教育水平”“剩余工作年限”等特征,相较于核心驱动因素,对模型输出影响较弱,改变效果不显著.

#### 4.SEM 中介效应验证

以职称为自变量 ( $X=T$ ), VA 为中介变量, Q 为因变量, 构建结构方程模型:

直接效应路径: 职称 $\rightarrow$ Q 的总效应为 0.30( $p<0.001$ ), 其中直接效应为 0.10( $p<0.05$ ), 间接效应通过 VA 实现 ( $0.80\times0.25=0.20$ ), 占总效应的 66.7%.

VA 与 Q 的各维度显著正相关 ( $r=0.297-0.401, p<0.001$ ), 其中与实践能力的培养 ( $r=0.401$ ) 和创新能力培养 ( $r=0.395$ ) 相关性最强, 表明数字胜任力提升对学生实践技能的促进更显著.

#### 5.结果整合与政策启示

综合模型结果, 教师数字胜任力提升的核心路径为: 高职称+高学历+实践导向教学+优质资源支持.具体表现为教授和博士群体的 VA 优势显著(分别比助教高 0.113 和 0.063 分), 但教龄每增加 5 年, VA 下降  $0.03\times5=0.15$  分, 需针对性设计“资深教师数字转型”培训项目; 双一流高校教师 VA 比地方高校高 0.15 分, 资源投入每增加 100 万元, VA 提升  $0.02\times100=2$  分, 建议建立“数字资源共享平台”缩小校际差距; 东部区域教师 VA 比西部高 0.10 分, 需通过“中西部数字教育专项基金”平衡资源分配; 将 VA 纳入教师考核(权重建议 20%), 并设立“数字化教学创新奖”, 激励教师通过提升数字能力间接提升人才培养质量(Q 与 VA 的中介效应占比超 60%).

#### 5.4 问题四模型建立与求解



图10 问题四流程图

本问在一二两问的基础上，旨在构建提升高校教师数字胜任力的策略模型，经分析选用 PDCA 循环和协同治理模型。PDCA 循环包含 Plan（计划）、Do（执行）、Check（检查）和 Act（行动）四个阶段，通过不断循环以持续改进提升教师数字胜任力的方案。协同治理模型则强调企业、政府、高校三方主体协同合作，整合各方资源，共同推动教师数字胜任力的提升。

提升高校教师数字胜任力需结合教师群体特征，实施分层分类培育路径。东部双一流高校教师起点高  $S_{pre} = 75$ ，干预效果显著  $\alpha_g = 0.8$ ，但存在协同投入冗余问题，因此聚焦“高阶创新”方向。具体通过开展每月 12 小时的 AI 教学工作坊，联合企业开发智能教研平台，并确保工具使用频率不低于每月 25 次，同时由政府提供 100 万元专项经费，支持教学研究与创新。而西部地方院校教师起点低  $S_{pre} = 60$ ，且工具使用频率低  $F=5$  次/月，致使技术赋能模型  $VA$  为负，所以以“基础赋能”为核心。具体措施包括推广低成本工具包，将基础数字技能培训时长从每月 5 小时提升至 8 小时，企业提供 30 万元免费工具试用，政府补贴 40 万元网络费用，并将工具使用频率提升至每月 10 次以上。

在教育数字化赋能增值评价方面，主要有三项举措。首先是过程数据采集，运用学习分析仪表盘实时采集教师在线教学时长、资源使用频率、学生评教反馈等数据，以此实现“过程评价”。其次是智能诊断与干预，借助 AI 模型分析教师数字胜任力短板，为西部新教师精准推送“工具使用 + 基础技能”组合培训，为东部教授推送“AI 创新 + 跨学科融合”研修课程。最后是构建多元协同机制，建立“企业 - 政府 - 高校”数字教育联盟，企业负责技术支持与工具迭代，政府将教师数字胜任力纳入职称评审等激励政策，高校建立“数字胜任力发展档案”，从而推动“增值评价”与“专业发展”的深度联动。

实施方案的核心要点涵盖动态监测、分层干预、技术赋能与多元协同四个方面。动态



监测旨在持续跟踪两类教师数字胜任力,东部双一流教授虽 VA 增速放缓但仍有提升空间预测 10.5 分,西部新教师增速稳定预测 8.5 分,并及时发现如西部教师工具使用不足等问题.分层干预根据两类教师特点,东部减少冗余投入,西部增加基础培训强度,实现资源优化配置.技术赋能基于工具使用频率 F 与 VA 的正相关关系( $\delta = 0.4$ ),重点推广工具使用,为西部教师提供“一键式”备课工具等.多元协同则充分发挥三方协同效应( $\rho = 0.001$ ),东部高校协同项贡献占总 VA 的 69.7%,西部院校占 47.3%,通过企业提供工具、政府补贴、高校组织培训等方式,有效放大资源效益.

## 六、模型评价与推广

### 6.1 模型的评价

本研究围绕高校教师数字胜任力,通过四个递进任务构建研究体系.任务一构建增值评价指标体系,任务二分析宏观环境因素影响,任务三探究个体属性作用机制,任务四转化为分层培育方案,形成“评价-分析-干预”闭环.该体系既揭示数字胜任力发展影响因素,又为高等教育数字化转型提供评价工具与实践路径,下文将对其进行模型评价与推广探讨.

#### 6.1.1 模型优点

本文所建立模型具有以下优点:

1. 在指标体系构建中,以《教师数字素养》行业标准为基准,结合高校教师职业特性,通过德尔菲法和层次分析法筛选指标并确定权重,既保证了理论依据的权威性,又通过专家群体决策和数学验证( $CR < 0.1$ )确保指标体系的科学性.多层线性模型和随机森林模型结合分析宏观因素,多元线性回归与结构方程模型探究微观机制,不同模型的选择适配对应研究问题,充分考虑变量间的线性与非线性关系、直接与间接影响,使模型结构严谨合理.数据驱动:基于数据驱动,利用真实数据进行计算和分析,保证了方案的科学性和合理性.

2. 指标体系扩展“科研数据可视化能力”等契合高校科研数字化需求的指标,突破传统框架;评价过程中采用增值评价理念,动态衡量教师数字胜任力发展,相较于静态评价更能反映真实提升情况.实践方案结合宏观分层与微观个体差异设计培育策略,引入“政府-企业-高校”协同生态和技术工具,实现了理论成果到实践应用的创新转化,对推动高等教育数字化转型具有较强的实用价值.

#### 6.1.2 模型缺点

本文所建立模型仍有以下不足:

德尔菲法中专家样本数量和覆盖范围可能影响指标筛选结果的普适性;模型中部分变量存在共线性问题(如年龄与教龄),虽采取处理措施,但仍可能对结果精度产生一定影响.学生评教分数标准化处理虽降低主观偏差,但仍难以完全消除评价主观性.此外,

模型未充分考虑突发政策变化、技术迭代等动态因素对教师数字胜任力发展的影响。

## 6.2 模型推广

本模型可推广至中小学教师数字胜任力评价与培育，根据不同教育阶段调整指标体系侧重点，如中小学更强调课堂互动数字化、学生管理数字化等能力；也适用于职业院校教师评价，结合职业教育实践教学特点，增加实训设备数字化操作、校企合作数字化管理等指标，助力各阶段教育数字化转型。

## 七、参考文献

- [1] 赵彬竹, 申文缙, 邹行行.教育数字化背景下初中生数字素养测评指标体系的建构[J/OL]. 教育测量与评价, 2025, 1-13 [2025-05-25].  
<http://kns.cnki.net/kcms/detail/43.1482.G4.20250523.1552.006.html>.
- [2] 李海龙, 陈翠荣, 崔红岩, 等.地方政府数字教育政策注意力配置差异与治理路径[J/OL]. 重庆高教研究, 2025, 1-15 [2025-05-25].  
<http://kns.cnki.net/kcms/detail/50.1028.G4.20250520.1844.002.html>.
- [3] 马云秀, 黄志诚, 王淦昌.基于“发现教育”的“数字赋能教学评”的实践研究[J]. 学校管理, 2025, (02): 16-20.
- [4] 杨俊峰.数字教育让知识更加“触手可及”[N]. 人民日报海外版, 2025-05-20 (005). DOI:10.28656/n.cnki.nmrh.2025.002355.
- [5] 阚阔, 刘林佳.向数字契约迈进: 联合国教科文组织推动高等教育数字化转型的价值理念、行动机制与实践经验[J]. 河北师范大学学报(教育科学版), 2025, 27 (03): 63-72. DOI:10.13763/j.cnki.jhebnu.esse.2025.03.007.
- [6] 申仁洪, 赵雨晴.特殊教育数字化的困境与突破: 基于数字正义视角[J]. 现代特殊教育, 2025, (10): 18-25.
- [7] 魏顺平, 杨雨璇, 吴淑苹.我国基础教育数字化发展水平及区域差异研究 —— 基于《中国教育信息化发展报告》(2017-2021)的分析[J/OL]. 甘肃开放大学学报, 2025, 1-14 [2025-05-25]. <http://kns.cnki.net/kcms/detail/62.5125.G4.20250517.2219.002.html>.
- [8] 闫智.夯实智慧教育发展“数字底座”[N]. 各界导报, 2025-05-16 (001). [9] 苏丹.数字教育背景下人工智能赋能成人教育发展研究——基于人工智能在欧美教育中应用的启示[J]. 继续教育研究, 2025, (06): 83-89.
- [10] 穆航, 刘善槐.数字技术赋能农村职业教育高质量发展的逻辑向度与实践路向[J]. 教育与职业, 2025, (10): 31-38. DOI:10.13615/j.cnki.1004-3985.2025.10.008.



## 附录

### Q1.py

```
import numpy as np

import pandas as pd

from scipy import stats

from sklearn.utils import resample

from numpy.linalg import eig


def bootstrap_delphi(experts_scores, n_iterations=1000):
    """
    基于 Bootstrap 的德尔菲法筛选指标

    :param experts_scores: 专家评分矩阵，形状为(n_experts, n_indicators)
    :param n_iterations: Bootstrap 抽样次数
    :return: 保留的指标索引列表
    """
    n_experts, n_indicators = experts_scores.shape
    retained_indicators = []

    for indicator in range(n_indicators):
        # 对每个指标进行 Bootstrap 抽样

        bootstrap_samples = []

        for _ in range(n_iterations):
            # 有放回地抽样

            sample = resample(experts_scores[:, indicator], replace=True)

            bootstrap_samples.append(sample)

        # 计算每个样本的 Kendall 协调系数

        w_values = []

        for sample in bootstrap_samples:
            # 计算样本的秩次

            ranks = stats.rankdata(sample)

            m = len(sample)

            # 计算第 k 个指标的专家评分秩次和

            R_k = np.sum(ranks)

            # 计算平均秩次和
```

```

R_bar = m * (m + 1) / 2

# 计算 Kendall 协调系数的分子
numerator = 12 * np.sum((ranks - R_bar)**2)

# 计算 Kendall 协调系数的分母
denominator = m**2 * (m**3 - m)

# 计算 Kendall 协调系数
w = numerator / denominator

w_values.append(w)

# 计算 W 的平均值
mean_w = np.mean(w_values)

# 判断是否保留指标
if mean_w > 0.5:
    retained_indicators.append(indicator)

return retained_indicators

def cloud_ahp(comparison_matrix):
    """
    云模型改进的层次分析法计算权重
    :param comparison_matrix: 判断矩阵
    :return: 权重向量, 一致性比率 CR
    """
    # 计算特征值和特征向量
    eigenvalues, eigenvectors = eig(comparison_matrix)

    # 获取最大特征值
    max_eigenvalue = np.max(eigenvalues.real)

    # 获取最大特征值的索引
    max_index = np.argmax(eigenvalues.real)

    # 获取最大特征值对应的特征向量
    weights = eigenvectors[:, max_index].real

    # 归一化权重
    weights = weights / np.sum(weights)

    # 一致性检验

```

```

n = comparison_matrix.shape[0]

# 计算一致性指标

CI = (max_eigenvalue - n) / (n - 1)

# 随机一致性指标表

RI = {1: 0, 2: 0, 3: 0.58, 4: 0.90, 5: 1.12, 6: 1.24, 7: 1.32, 8: 1.41, 9: 1.45}.get(n, 1.45)

# 计算一致性比率

CR = CI / RI

return weights, CR

def calculate_tei(scores, weights):
    """
    计算数字胜任力总指数

    :param scores: 各指标得分，形状为(n_indicators,)
    :param weights: 各指标权重，形状为(n_indicators,)
    :return: 总指数 TEI
    """
    return np.sum(scores * weights)

def calculate_value_added(tei_t, tei_0):
    """
    计算增值率

    :param tei_t: 当期总指数
    :param tei_0: 基线总指数
    :return: 增值率 V_t
    """
    if tei_0 < 60:
        alpha = 1.2
    elif 60 <= tei_0 < 80:
        alpha = 1.0
    else:
        alpha = 0.8

    return ((tei_t - tei_0) / tei_0) * alpha

def main():
    # 示例数据

```

```

# 假设有 20 个专家对 10 个指标进行评分(1-5 分)

np.randomseed(42)

# 生成专家评分矩阵

experts_scores = np.random.randint(1, 6, size=(20, 10))


# Step 1: 指标体系扩展 (在数据准备阶段完成)


# Step 2: 基于 Bootstrap 的德尔菲法筛选指标

retained_indicators = bootstrap_delphi(experts_scores)

print(f"保留的指标索引: {retained_indicators}")


# Step 3: 基于 Cloud Model - AHP 的指标权重计算

# 示例判断矩阵 (3 个指标的比较)

comparison_matrix = np.array([

    [1, 3, 5],

    [1/3, 1, 2],

    [1/5, 1/2, 1]

])


# 进行一致性检验, 若不通过则重新调整

while True:

    weights, CR = cloud_ahp(comparison_matrix)

    if CR < 0.1:

        break

    else:

        print("一致性检验未通过, 需要调整判断矩阵.")

        # 这里可以添加调整判断矩阵的逻辑, 例如重新邀请专家打分

        break # 暂时简单处理, 直接跳出循环


print(f"权重: {weights}, 一致性比率 CR: {CR:.4f}")


# Step 4: 计算基线得分与当期得分

# 示例数据: 3 个指标的得分

baseline_scores = np.array([70, 80, 60])

current_scores = np.array([80, 85, 75])


tei_0 = calculate_tei(baseline_scores, weights)

```



```

tei_t = calculate_tei(current_scores, weights)

print(f"基线总指数: {tei_0:.2f}, 当期总指数: {tei_t:.2f}")

# Step 5: 计算增值率

v_t = calculate_value_added(tei_t, tei_0)

print(f"增值率: {v_t:.4f}")

if __name__ == "__main__":
    main()

```

## Q2.py

```

import pandas as pd

import numpy as np

import statsmodels.api as sm

from statsmodels.stats.outliers_influence import variance_inflation_factor

from sklearn.preprocessing import StandardScaler

from sklearn.experimental import enable_iterative_imputer

from sklearn.impute import IterativeImputer

import warnings

warnings.filterwarnings('ignore')

def data_preprocessing(raw_data):
    """
    数据预处理函数
    包含缺失值填补、连续变量标准化、分类变量虚拟化处理
    """
    # 1. 缺失值填补 - 使用多重插补法
    # 选择可能存在缺失值的变量进行插补

    if 'Tenure' in raw_data.columns and 'Title' in raw_data.columns:
        # 确保没有缺失值

        if raw_data[['Tenure', 'Title']].isnull().any().any():
            imputer = IterativeImputer(max_iter=10, random_state=42)

            imputed_data = imputer.fit_transform(raw_data[['Tenure', 'Title']])

            # 将插补后的数据放回原始数据中

            raw_data['Tenure'] = imputed_data[:, 0]

            # 职称是有序分类变量，取整

```

```

raw_data['Title'] = np.round(imputed_data[:, 1])

# 2. 连续变量标准化

scaler = StandardScaler()

# 对教龄进行标准化处理

if 'Tenure' in raw_data.columns:

    raw_data['Tenure_std'] = scaler.fit_transform(raw_data[['Tenure']])

# 3. 分类变量虚拟化处理

# 高校类型：双一流=1，地方院校=0

if 'UnivType' in raw_data.columns:

    # 确保映射后的数据类型是数值型

    raw_data['UnivType'] = pd.to_numeric(raw_data['UnivType'].map({'双一流': 1, '地方院校': 0}), errors='coerce')

    # 处理可能的缺失值（如果有无效的分类值）

    if raw_data['UnivType'].isnull().any():

        print("警告: UnivType 列包含无法映射的值，已将其设置为 NaN")

        raw_data['UnivType'] = raw_data['UnivType'].fillna(0) # 假设默认为地方院校

# 区域位置：东部=1，中部=2，西部=0(参照组)

# 使用 get_dummies 将区域位置转换为虚拟变量，删除第一个虚拟变量以避免虚拟变量陷阱

if 'Region' in raw_data.columns:

    # 确保 Region 列是分类类型

    raw_data['Region'] = raw_data['Region'].astype('category')

    raw_data = pd.get_dummies(raw_data, columns=['Region'], prefix='Region', drop_first=True)

# 将所有布尔列转换为整数类型

for col in raw_data.columns:

    if raw_data[col].dtype == 'bool':

        raw_data[col] = raw_data[col].astype(int)

        print(f"已将列 {col} 从 bool 转换为 int")

return raw_data

def calculate_tei(current_scores, baseline_scores):

    """

    计算教师数字胜任力增值指数(TEI)

    TEI=(当前得分 - 基线得分)/基线得分 * 100%

    """

    # 避免除零错误

    mask = baseline_scores != 0

    tei = np.zeros_like(current_scores, dtype=float)

    tei[mask] = (current_scores[mask] - baseline_scores[mask]) / baseline_scores[mask] * 100

    return tei

```

```

def build_base_model(data):
    """
    构建基础线性回归模型
    TEI ~ UnivType + Region + 控制变量
    """
    # 检查必要的列是否存在
    required_cols = ['UnivType', 'Title', 'Tenure_std', 'TEI']
    region_cols = ['Region_东部', 'Region_中部']
    available_region_cols = [col for col in region_cols if col in data.columns]

    if not all(col in data.columns for col in required_cols) or len(available_region_cols) == 0:
        missing = [col for col in required_cols if col not in data.columns] + \
            [col for col in region_cols if col not in data.columns]
        raise ValueError(f"构建基础模型缺少必要的列: {missing}")

    # 准备自变量和因变量
    X = data[['UnivType', 'Title', 'Tenure_std'] + available_region_cols]

    # 打印数据类型信息，用于调试
    print("\n 构建模型前的数据类型检查:")
    for col in X.columns:
        print(f"{col}: {X[col].dtype}, 唯一值: {X[col].unique()[:5]}")

    # 确保所有数据都是数值类型
    for col in X.columns:
        if X[col].dtype == 'object' or pd.api.types.is_categorical_dtype(X[col]):
            try:
                X[col] = pd.to_numeric(X[col])
                print(f"成功将列 {col} 转换为数值类型")
            except ValueError:
                print(f"列 {col} 包含非数值数据，将转换为分类编码")
                X[col] = X[col].astype('category').cat.codes # 转换为分类编码

    # 再次检查数据类型
    print("\n 转换后的数据类型:")
    for col in X.columns:
        print(f"{col}: {X[col].dtype}")

```

```

# 检查是否有缺失值
if X.isnull().any().any():
    print("警告: 模型自变量中存在缺失值, 将用 0 填充")
    X = X.fillna(0)

# 添加截距项
X = sm.add_constant(X)
y = data['TEI']

# 构建并拟合模型
model = sm.OLS(y, X).fit()

# 多重共线性检验
vif = pd.DataFrame()
vif["Variable"] = X.columns
# 计算每个自变量的方差膨胀因子
vif["VIF"] = [variance_inflation_factor(X.values, i) for i in range(X.shape[1])]
return model, vif

def build_interaction_model(data):
    """
    构建包含交互项的扩展模型
    TEI ~ UnivType + Region + UnivType*Region + 控制变量
    """
    # 检查必要的列是否存在
    required_cols = ['UnivType', 'Title', 'Tenure_std', 'TEI']
    region_cols = ['Region_东部', 'Region_中部']
    available_region_cols = [col for col in region_cols if col in data.columns]

    if not all(col in data.columns for col in required_cols) or len(available_region_cols) == 0:
        missing = [col for col in required_cols if col not in data.columns] + \
            [col for col in region_cols if col not in data.columns]
        raise ValueError(f"构建交互模型缺少必要的列: {missing}")

    # 创建交互项
    for region in available_region_cols:
        interaction_col = f'UnivType_{region.split("_")[1]}'
        data[interaction_col] = data['UnivType'] * data[region]

```

```

# 获取所有交互列

interaction_cols = [f'UnivType_{region.split("_")[1]}' for region in available_region_cols]

# 准备自变量和因变量

X = data[['UnivType', 'Title', 'Tenure_std'] + available_region_cols + interaction_cols]

# 确保所有数据都是数值类型

for col in X.columns:

    if X[col].dtype == 'object' or pd.api.types.is_categorical_dtype(X[col]):

        try:

            X[col] = pd.to_numeric(X[col])

        except ValueError:

            print(f"列 {col} 包含非数值数据，将转换为分类编码")

            X[col] = X[col].astype('category').cat.codes # 转换为分类编码

# 检查是否有缺失值

if X.isnull().any().any():

    print("警告: 模型自变量中存在缺失值，将用 0 填充")

    X = X.fillna(0)

# 添加截距项

X = sm.add_constant(X)

y = data['TEF']

# 构建并拟合模型

model = sm.OLS(y, X).fit()

return model

def main():

    # Step 1: 数据准备

    try:

        raw_data = pd.read_csv('teacher_data.csv') # 示例数据

        print(f"成功加载数据，共 {len(raw_data)} 条记录")

    except FileNotFoundError:

        print("错误: 找不到 teacher_data.csv 文件，请确保数据文件路径正确.")

        return

    except Exception as e:

        print(f"读取数据时发生错误: {e}")

        return

```



```

# 打印数据基本信息和前几行

print("\n 数据基本信息:")

raw_data.info()

print("\n 数据前几行:")

print(raw_data.head().to_csv(sep='^t', na_rep='nan'))

# Step 2: 数据预处理

processed_data = data_preprocessing(raw_data)

print("\n 数据预处理后各列的数据类型:")

for col in processed_data.columns:

    print(f'{col}: {processed_data[col].dtype}')

# 计算 TEI (假设已有当前得分和基线得分)

if 'CurrentScore' in processed_data.columns and 'BaselineScore' in processed_data.columns:

    processed_data['TEI'] = calculate_tei(

        processed_data['CurrentScore'].values,

        processed_data['BaselineScore'].values

    )

else:

    print("错误: 数据中缺少计算 TEI 所需的 CurrentScore 或 BaselineScore 列")

    return

# 检查预处理后的数据是否包含所有必要的列

required_columns = ['UnivType', 'Title', 'Tenure_std', 'CurrentScore', 'BaselineScore', 'TEI']

missing_columns = [col for col in required_columns if col not in processed_data.columns]

if missing_columns:

    print(f"警告: 预处理后的数据缺少以下列: {missing_columns}")

    print("这可能导致后续分析出现问题.")

# 检查数据是否包含足够的样本

if len(processed_data) < 10:

    print("警告: 样本量过小, 可能导致不可靠的统计结果")

# 保存预处理后的数据

processed_data.to_csv('processed_teacher_data.csv', index=False)

print("\n 已保存预处理后的数据到 processed_teacher_data.csv")

# Step 3: 构建基础模型

try:

    base_model, vif = build_base_model(processed_data)

    print("\n 基础模型回归结果:")

```

```

print(base_model.summary())

print("\n 多重共线性检验(VIF):")

print(vif)

except Exception as e:

    print(f"构建基础模型时发生错误: {e}")

    # 输出有问题的数据, 只打印存在的列

    print("\n 可能有问题的数据:")

    problematic_cols = ['UnivType', 'Title', 'Tenure_std', 'Region_东部', 'Region_中部', 'TEI']

    available_cols = [col for col in problematic_cols if col in processed_data.columns]

    print(processed_data[available_cols].head().to_csv(sep='\t', na_rep='nan'))

    return

# Step 4: 模型扩展(交互效应)

# 改进 VIF 检查逻辑, 排除截距项的 VIF

intercept_vif = vif[vif['Variable'] == 'const']['VIF'].values[0]

predictor_vifs = vif[vif['Variable'] != 'const']['VIF']

if all(predictor_vifs < 10): # 通常认为 VIF<10 时多重共线性可以接受

    try:

        interaction_model = build_interaction_model(processed_data)

        print("\n 扩展模型(交互效应)回归结果:")

        print(interaction_model.summary())

        # 模型比较

        print("\n 模型比较(似然比检验):")

        lr_test = 2 * (interaction_model.llf - base_model.llf)

        # 计算自由度: 交互项数量

        region_cols = ['Region_东部', 'Region_中部']

        available_region_cols = [col for col in region_cols if col in processed_data.columns]

        df = len(available_region_cols)

        p_value = 1 - sm.stats.chi2.cdf(lr_test, df)

        print(f"卡方值: {lr_test:.3f}, 自由度: {df}, p 值: {p_value:.3f}")

        if p_value < 0.05:

            print("交互项显著, 应采用扩展模型")

        else:

            print("交互项不显著, 建议采用基础模型")

    except Exception as e:

        print(f"构建交互模型时发生错误: {e}")

```

```

else:

    print("\n 存在严重多重共线性，请调整变量后重新建模")

    high_vif_vars = vif[vif['Variable'] != 'const'][vif['VIF'] >= 10]

    if not high_vif_vars.empty:

        print("高 VIF 变量:")

        print(high_vif_vars)

if __name__ == '__main__':

    main()

```

## Q3.py

```

import numpy as np
import pandas as pd

from sklearn.impute import IterativeImputer
from sklearn.decomposition import PCA
from sklearn.preprocessing import StandardScaler

import pymc as pm

import arviz as az

from sklearn.ensemble import RandomForestRegressor
from sklearn.linear_model import LassoCV

import matplotlib.pyplot as plt

# 数据预处理函数

def data_preprocessing(data):

    """

    数据预处理步骤：

    1. 处理缺失值

    2. 处理异常值

    3. 主成分分析处理共线性

    4. 标准化处理

    """

    # 1. 多重插补处理缺失值

    # 使用 IterativeImputer 进行多重插补，max_iter 为最大迭代次数，random_state 为随机种子

    # 仅对数值列进行插补

    numeric_cols = data.select_dtypes(include=[np.number]).columns.tolist()

    if not numeric_cols:

        raise ValueError("数据中没有可处理的数值列")

```

```

imp = IterativeImputer(max_iter=10, random_state=0)

data_imputed = data.copy()

data_imputed[numeric_cols] = imp.fit_transform(data[numeric_cols])

# 2. 异常值处理 - 使用 3σ 原则
# 对年龄、教龄、周授课量这三个连续变量进行异常值处理
for col in ['age', 'teaching_age', 'weekly_lectures']:
    if col in data_imputed.columns:
        mean = data_imputed[col].mean() # 计算该列的均值
        std = data_imputed[col].std() # 计算该列的标准差
        # 将该列的值限制在均值加减 3 倍标准差的范围内
        data_imputed[col] = data_imputed[col].clip(mean - 3 * std, mean + 3 * std)

# 3. 主成分分析处理年龄和教龄的共线性
# 确保这两列存在
if 'age' in data_imputed.columns and 'teaching_age' in data_imputed.columns:
    # 创建 PCA 对象，指定主成分数量为 1
    pca = PCA(n_components=1)

    # 提取年龄和教龄两列数据
    age_teaching = data_imputed[['age', 'teaching_age']]

    # 进行主成分分析并转换数据
    Z1 = pca.fit_transform(age_teaching)

    # 将主成分分析结果添加到数据中
    data_imputed['Z1'] = Z1

    # 打印主成分解释方差比例
    print(f"主成分分析解释方差比例: {pca.explained_variance_ratio_[0]:.4f}")
else:
    print("警告: 数据中缺少'age'或'teaching_age'列，无法进行主成分分析")
    data_imputed['Z1'] = 0 # 添加占位列，避免后续代码出错

# 4. 标准化处理
# 创建 StandardScaler 对象，用于数据标准化
scaler = StandardScaler()

# 选择需要标准化的列
# 确保这些列存在
numeric_cols = ['Z1', 'weekly_lectures']

```

```

available_cols = [col for col in numeric_cols if col in data_imputed.columns]

if available_cols:
    # 对选定列进行标准化处理
    data_imputed[available_cols] = scaler.fit_transform(data_imputed[available_cols])
else:
    print("警告: 没有找到可标准化的列")
# 确保分类变量是正确的类型
for col in ['gender', 'title', 'major', 'degree']:
    if col in data_imputed.columns:
        data_imputed[col] = data_imputed[col].astype('category')
return data_imputed
# 贝叶斯结构方程模型
def build_bsem_model(data):
    """
    构建贝叶斯结构方程模型
    包括测量方程和结构方程
    """
    try:
        # 确保所需的列存在
        required_cols = ['gender', 'title', 'major', 'degree', 'weekly_lectures', 'Z1', 'TEI', 'Q']
        missing_cols = [col for col in required_cols if col not in data.columns]

        if missing_cols:
            raise ValueError(f"构建模型缺少必要的列: {missing_cols}")

        import pymc as pm
        import arviz as az

        print(f"PyMC 版本: {pm.__version__}")
        print(f"ArviZ 版本: {az.__version__}")

        with pm.Model() as model:
            # 先验分布设定
            # 潜在变量 $\xi$ 和 $\eta$ 的先验, 假设它们服从均值为0, 标准差为1的正态分布
             $\xi$  = pm.Normal('xi', mu=0, sigma=1, shape=len(data))
             $\beta$  = pm.Normal('beta', mu=0, sigma=1) # 路径系数

```



```

#  $\xi$  与  $\eta$  之间的结构关系

 $\eta\_mean = \beta * \xi$ 

 $\eta = pm.Normal(\eta', mu=\eta\_mean, sigma=1, shape=len(data))$ 

# 路径系数的先验, 假设路径系数服从均值为 0, 标准差为 1 的正态分布

 $\lambda = pm.Normal(\lambda', mu=0, sigma=1, shape=8)$  # 对应 8 个测量方程

# 测量误差的先验, 假设测量误差服从半正态分布

 $\delta = pm.HalfNormal(\delta', sigma=1, shape=8)$ 

# 测量方程

 $pm.Normal(X1', mu=\lambda[0] * \xi, sigma=\delta[0], observed=data[gender])$ 

 $pm.Normal(X3', mu=\lambda[1] * \xi, sigma=\delta[1], observed=data[title])$ 

 $pm.Normal(X5', mu=\lambda[2] * \xi, sigma=\delta[2], observed=data[major])$ 

 $pm.Normal(X6', mu=\lambda[3] * \xi, sigma=\delta[3], observed=data[degree])$ 

 $pm.Normal(X7', mu=\lambda[4] * \xi, sigma=\delta[4], observed=data[weekly\_lectures])$ 

 $pm.Normal(Z1', mu=\lambda[5] * \xi, sigma=\delta[5], observed=data[Z1])$ 


# 修正 TEI 和 Q 的测量方程

 $pm.Normal(TEI', mu=\lambda[6] * \xi + \lambda[7] * \eta, sigma=\delta[6], observed=data[TEI])$ 

 $pm.Normal(Q', mu=\lambda[7] * \xi + \lambda[6] * \eta, sigma=\delta[7], observed=data[Q])$ 

# 模型拟合

# 使用马尔可夫链蒙特卡罗 (MCMC) 算法进行采样

print("开始采样...")

trace = pm.sample(1000, tune=1000, chains=2, target_accept=0.9, cores=1)

print("采样完成")

return trace

except Exception as e:

    import sys

    import traceback

    print(f"构建贝叶斯模型时发生错误: {str(e)}")

    print("完整错误堆栈:")

    traceback.print_exc(file=sys.stdout)

    raise

# 正则化中介效应分析

def regularized_mediation(data):

    """

    使用 Lasso 回归进行中介效应分析

    """

```

```

# 确保所需的列存在

required_cols = ['gender', 'title', 'major', 'degree', 'weekly_lectures', 'Z1', 'TEI', 'Q']

missing_cols = [col for col in required_cols if col not in data.columns]

if missing_cols:

    raise ValueError(f"中介效应分析缺少必要的列: {missing_cols}")

# 自变量
X = data[['gender', 'title', 'major', 'degree', 'weekly_lectures', 'Z1']]

# 对分类变量进行 one-hot 编码
X = pd.get_dummies(X, drop_first=True)

# 中介变量和因变量
M = data['TEI']
Y = data['Q']

# 路径 a: X -> M
# 创建 LassoCV 对象，进行 5 折交叉验证
lasso_a = LassoCV(cv=5)

# 拟合模型
lasso_a.fit(X, M)

# 获取路径 a 的系数
a_path = lasso_a.coef_

# 路径 b: M -> Y (控制 X)
# 将自变量和中介变量合并
XM = pd.concat([X, M], axis=1)

# 创建 LassoCV 对象，进行 5 折交叉验证
lasso_b = LassoCV(cv=5)

# 拟合模型
lasso_b.fit(XM, Y)

# 获取路径 b 的系数，即中介变量的系数
b_path = lasso_b.coef_[-1] # 最后一个系数对应 M

# 路径 c': X -> Y (直接效应)
# 创建 LassoCV 对象，进行 5 折交叉验证
lasso_c = LassoCV(cv=5)

# 拟合模型
lasso_c.fit(X, Y)

# 获取直接效应的系数

```

```

c_path = lasso_c.coef_

# 中介效应

mediation_effect = a_path * b_path

return {

    'a_path': a_path,

    'b_path': b_path,

    'c_path': c_path,

    'mediation_effect': mediation_effect,

    'feature_names': X.columns.tolist()

}

# 因果森林分析

def causal_forest_analysis(data):

    """

    使用随机森林进行因果分析

    """

    # 确保所需的列存在

    required_cols = ['gender', 'title', 'major', 'degree', 'weekly_lectures', 'Z1', 'TEI', 'Q']

    missing_cols = [col for col in required_cols if col not in data.columns]

    if missing_cols:

        raise ValueError(f"因果森林分析缺少必要的列: {missing_cols}")

    # 自变量

    X = data[['gender', 'title', 'major', 'degree', 'weekly_lectures', 'Z1']]

    # 对分类变量进行 one-hot 编码

    X = pd.get_dummies(X, drop_first=True)

    # 因变量

    Y_TEI = data['TEI']

    Y_Q = data['Q']

    # 构建模型

    # 创建随机森林回归器，指定树的数量为 100，随机种子为 42

    rf_te1 = RandomForestRegressor(n_estimators=100, random_state=42)

    rf_q = RandomForestRegressor(n_estimators=100, random_state=42)

    # 拟合模型

    rf_te1.fit(X, Y_TEI)

    rf_q.fit(X, Y_Q)

```

```

# 特征重要性

# 获取随机森林模型中各特征的重要性
importance_tei = rf_tei.feature_importances_
importance_q = rf_q.feature_importances_

return {
    'TEI_importance': importance_tei,
    'Q_importance': importance_q,
    'feature_names': X.columns.tolist()
}

# 可视化结果

def visualize_results(mediation_results, causal_results):
    """
    可视化分析结果
    """
    # 创建图形
    fig, axes = plt.subplots(1, 2, figsize=(15, 6))

    # 1. 中介效应可视化

    feature_names = mediation_results['feature_names']
    mediation_effect = mediation_results['mediation_effect']

    # 获取绝对值最大的前5个中介效应
    top_indices = np.argsort(np.abs(mediation_effect))[-5:]
    top_features = [feature_names[i] for i in top_indices]
    top_effects = [mediation_effect[i] for i in top_indices]

    # 绘制柱状图
    axes[0].barh(top_features, top_effects)
    axes[0].set_title('中介效应分析 (Top 5)')
    axes[0].set_xlabel('(中介效应值)')
    axes[0].axvline(x=0, color='black', linestyle='--', alpha=0.5)

    # 2. 特征重要性可视化

    feature_names = causal_results['feature_names']
    importance_tei = causal_results['TEI_importance']
    importance_q = causal_results['Q_importance']

```

```

# 获取 TEI 相关的前 5 个重要特征

tei_indices = np.argsort(importance_tei)[-5:]

tei_features = [feature_names[i] for i in tei_indices]

tei_importance = [importance_tei[i] for i in tei_indices]


# 绘制柱状图

axes[1].barh(tei_features, tei_importance, color='skyblue')

axes[1].set_title('TEI 的特征重要性 (Top 5)')

axes[1].set_xlabel('重要性分数')


plt.tight_layout()

plt.savefig('analysis_results.png', dpi=300, bbox_inches='tight')

plt.show()

# 主程序
def main():

    # 1. 加载数据

    # 假设数据已经加载到 df 中, 包含以下列:

    # gender, age, title, teaching_age, major, degree, weekly_lectures, TEI, Q

    # 这里使用模拟数据

    np.random.seed(42)

    n = 500

    data = pd.DataFrame({

        'gender': np.random.randint(0, 2, n), # 性别 (0=女, 1=男)

        'age': np.random.normal(40, 10, n).clip(20, 60), # 年龄

        'title': np.random.randint(1, 5, n), # 职称 (1-4)

        'teaching_age': np.random.normal(15, 8, n).clip(0, 40), # 教龄

        'major': np.random.randint(0, 2, n), # 学科 (0=文科, 1=理科)

        'degree': np.random.randint(1, 4, n), # 学历 (1=学士, 2=硕士, 3=博士)

        'weekly_lectures': np.random.normal(10, 3, n).clip(0, 20), # 周授课量

        'TEI': np.random.normal(50, 10, n), # 教师数字胜任力增值指数

        'Q': np.random.normal(50, 10, n) # 教学质量评分

    })

    # 添加一些相关性, 使模型更有意义

    data['TEI'] = (

        20 +

        5 * data['gender'] +

```

```

3 * data['title'] +
2 * data['degree'] +
0.5 * data['weekly_lectures'] +
0.3 * data['age'] +
np.random.normal(0, 5, n)
)

data['Q'] = (
30 +
0.6 * data['TEI'] +
2 * data['title'] +
1 * data['degree'] +
0.2 * data['teaching_age'] +
np.random.normal(0, 5, n)
)

# 2. 数据预处理
print("正在进行数据预处理...")

processed_data = data_preprocessing(data)

# 保存预处理后的数据
processed_data.to_csv('processed_teacher_data.csv', index=False)
print(f"已保存预处理后的数据，包含 {len(processed_data)} 条记录和 {len(processed_data.columns)} 列")

# 打印数据基本信息
print("\n 预处理后的数据基本信息:")
processed_data.info()

# 3. 贝叶斯结构方程模型
print("\n 正在构建贝叶斯结构方程模型...")

try:
    trace = build_bsem_model(processed_data)

# 4. 模型诊断
print("\n 模型诊断结果:")

# 打印模型参数的统计摘要
print(az.summary(trace))

# 绘制参数的跟踪图

```



```

az.plot_trace(trace)

plt.savefig('bsem_trace.png', dpi=300, bbox_inches='tight')

plt.close()

# 绘制森林图
az.plot_forest(trace, var_names=[' $\beta$ ', ' $\gamma$ '])

plt.savefig('bsem_forest.png', dpi=300, bbox_inches='tight')

plt.close()

print("贝叶斯模型构建完成，结果已保存")
except Exception as e:
    print(f"构建贝叶斯模型时发生错误: {e}")

    trace = None

# 5. 正则化中介效应分析
print("\n 正在进行正则化中介效应分析...")

try:
    mediation_results = regularized_mediation(processed_data)

    print("\n 中介效应分析结果:")

    # 打印路径系数
    print("\n 路径 a 系数(X->M):")

    for feat, coef in zip(mediation_results['feature_names'], mediation_results['a_path']):
        if abs(coef) > 1e-6: # 忽略接近零的系数
            print(f" {feat}: {coef:.4f}")

    print(f"\n 路径 b 系数(M->Y): {mediation_results['b_path']:.4f}")

    print("\n 直接效应 c'(X->Y):")

    for feat, coef in zip(mediation_results['feature_names'], mediation_results['c_path']):
        if abs(coef) > 1e-6: # 忽略接近零的系数
            print(f" {feat}: {coef:.4f}")

    print("\n 中介效应(a*b):")

    for feat, effect in zip(mediation_results['feature_names'], mediation_results['mediation_effect']):
        if abs(effect) > 1e-6: # 忽略接近零的效应
            print(f" {feat}: {effect:.4f}")

except Exception as e:

```

```

print(f"中介效应分析时发生错误: {e}")

mediation_results = None

# 6. 因果森林分析

print("\n 正在进行因果森林分析...")

try:

    causal_results = causal_forest_analysis(processed_data)

    print("\n 特征重要性(TEI):")

    for feat, importance in zip(causal_results['feature_names'], causal_results['TEI_importance']):

        print(f" {feat}: {importance:.4f}")


    print("\n 特征重要性(Q):")

    for feat, importance in zip(causal_results['feature_names'], causal_results['Q_importance']):

        print(f" {feat}: {importance:.4f}")

except Exception as e:

    print(f"因果森林分析时发生错误: {e}")

    causal_results = None

# 7. 可视化结果

if mediation_results and causal_results:

    print("\n 正在生成可视化结果...")

    visualize_results(mediation_results, causal_results)

    print("可视化结果已保存为 analysis_results.png")

    print("\n 分析完成, 请参考上述结果进行解释.")

if __name__ == "__main__":

    main()

```