

“康养城市建设”：AI 技术的应用与展望

摘要

2025 年全国两会期间，康养城市建设备受关注，代表委员们提出了诸多建议。全国政协委员金李提出盘活“空置房”用于康养产业转型，全国人大代表程伟强调加快发展数字家庭照亮“银发生活”。安徽省人民政府发布意见推动康养产业与多领域融合，地方上广德市和吉林也在积极推进康养产业发展战略。然而，面对有限资源，如何更好地优化康养设施，提升康养服务成为更重要的问题，基于此，本文初步建立了以K-means聚类分析模型为核心，利用了肘部法、熵权法、Critic赋权法、主观赋权法、岭回归等方法来解决相关问题。

针对问题一，本研究针对北京市城区养老资源分布情况，采用K-means聚类算法将北京各个城区划分为三个类别（资源发达区、资源落后区、资源中部区），对三个类别的人均可支配收入、当地图书馆总藏书、人均绿化面积、医疗资源、养老机构数量、PM2.5（微克/立方米）等数据进行权重分析，获得每个类别的地区指标的轻重差别，进行借此反映不同城区养老资源的相对优劣状况。

针对问题二，本研究在问题一K-means 聚类算法的基础上，整合城市养老资源评价指标，并收集若个城市相关数据，使用Critic赋权法、主观赋权法对所选取到的城市进行康养城市排名，整理并结合两种赋权法所获得的排名情况，分析康养城市排名情况。从中可以发现在Critic赋权法中广州市、重庆市、成都市以及南京市等经济发达的城市的排名均靠前并且与2024年排名相接近。而在主观赋权法所构建的模型结果中，可以得到攀枝花市、雅安市以及贵阳市等经济欠发达但环境质量较高的城市排名靠前并且与2024年康养城市排名相接近。后续可以根据模型构建相关因素，指导城市系统优化，为老龄人口提供更优质的服务。

针对问题三，本研究在结合问题一与问题二所构建的模型以及获得的康养城市排名情况的基础上，使用lasso岭回归构建康养资源优化配置模型，建立城市最大化康养服务覆盖率、最大化资源利用效率以及最小化成本函数，分析在成本最小化的同时如何实现资源的最大化利用。得到医院、城市绿化覆盖率、文化服务供给、人口规模缩减、人均收入方面的减少，同时参加养老保障人数提升可以将预期寿命从82.32提升至85.19，康养成本从1388682.63个单位降低至1319262.82个单位。后续政府部门可以从上述方面改善城市建设，实现康养城市建设。

关键词：K-means分析 熵权法 Critic赋权法 主观赋权法 岭回归

一、问题背景与重述

1.1 问题背景

当今，面对人口老龄化越来越严重的情况，如何能够更好地服务于老龄人口成为重要议题。2025 年全国两会期间，康养城市建设成为热点议题。多位代表和委员围绕康养城市建设、智慧养老、医养融合等议题提出了重要建议。如全国政协委员金李提出盘活“空置房”用于康养产业转型，全国人大代表程伟强调加快发展数字家庭，用科技之光照亮“银发生活”。安徽省人民政府发布《关于支持康养产业高质量发展的意见》，提出要推动康养产业与医疗、旅游、文化等领域的深度融合。在地方层面，广德市积极推进“康养名城”发展战略，通过优化康养设施布局、提升智慧养老水平、加强医养融合等措施，打造高品质的康养目的地。吉林两会也明确表示要打造高品质旅居康养目的地。这些实践表明，康养城市建设不仅是国家层面的战略部署，也是地方发展的实际需求。

然而，当前康养城市建设仍面临诸多挑战。如康养资源分布不均衡，部分地区的康养设施、专业人才等资源相对匮乏，而一些地区则存在资源闲置浪费的情况。智慧养老技术应用不足，虽然市场上出现了一些智慧养老产品和服务，但整体普及率较低，老年人的接受度和使用能力也存在差异。医养融合深度不够，医疗机构与养老机构之间的合作不够紧密，信息共享和资源整合存在障碍，导致医养结合的服务模式不够完善。如何在有限的资源条件下，优化康养设施布局，提升康养服务质量，推动智慧养老与康养产业的深度融合，是亟待解决的问题。

1.2 我们的工作

在本研究中，本文系统地构建城市康养指数，帮助解决城市康养资源的全面评估以及未来城市康养资源分配问题，针对不同的内容，我们的工作如下：

1. 收集或模拟该城市内不同区域的康养资源数据，涵盖医疗设施、养老机构、公园绿地、文化设施的数量与分布密度，结合居民健康状况数据，综合评估当前康养资源分布的合理性，同时基于现状分析结果，优化康养资源布局的初步思路，解决资源分布不均衡问题，为康养城市建设提供有力支撑。

2. 构建一个全面的康养城市综合评价模型，从多个维度设定科学合理的评价指标。通过运用该模型进行计算与分析，深入剖析当前城市康养水平的优势所在以及存在的不足之处。在此基础上，进一步提出具有针对性的改进建议，旨在为康养城市建设提供坚实可靠的科学依据，助力城市康养事业的高质量发展。

3. 结合已有康养城市评价结果，建立康养资源优化配置模型，最大化康养服务的覆盖率和资源利用效率，与此同时实现最小化成本。并根据模型结果提供具体实施策略，为康养城市建设出谋划策。

二、问题一的求解

2.1 问题解析

问题一要求收集及使用模型数据分析某城市内不同区域康养资源分配情况，并结合居民健康状况数据，分析当前资源分配的合理性，并提出优化康养资源布局的初步思路。

2.2 模型构建

2.2.1 数据处理

为了准确评估北京市不同地区康养资源的分布情况，本研究选取了多个潜在影响因素，包括各区的生产总值、卫生行业投入、每千人医疗技术人员数量、人均绿化面积和养老机构数量等，作为模型分类与评估的标准。这些数据来源于北京市统计局和北京区域统计年鉴，确保了数据的可靠性和权威性。

在数据预处理阶段，我们首先从原始数据文件中提取了涵盖GDP、GDP增速、卫生行业投入、人均可支配收入、图书馆总藏书量、卫生机构数量、每千人医师数、总床位数、人均绿化面积和养老机构数量等原始数据。这些数据综合反映了北京市各区域的经济基础、医疗质量、养老设施和生态状况，为康养城市评价提供了基础变量。

在此基础上，我们计划对数据进行进一步处理，包括统一量纲和增加聚类标签。由于DEA等模型对数据量纲较为敏感，需要将原始值转换为无量纲指标，通过标准化消除量纲影响，因此我们将原始数据进行Min-Max标准化变换至[0, 1]区间内，以适配DEA模型。

在数据处理过程中，我们划分了不同指标：投入指标包括PM2.5、环保支出和煤炭燃烧状况，产出指标包括养老机构数量、GDP和医疗资源。这些指标反映了康养环境的成本消耗和供给能力，为后续的分析 and 模型构建提供了重要依据。

通过上述数据处理和分析，我们能够更准确地评估北京市不同区域的康养资源分布情况，为相关政策制定和资源配置提供科学依据。

2.2.2 数据分析与模型选择

考虑到评估康养资源分布情况需要对不同区域的各种因素进行处理，我们构建了K-means聚类分析模型以实现这一目标。K-means聚类算法具备出色的数据模式识别能力，能在高维数据集中迅速发现数据的内在结构和分类标准。这一模型不仅能有效对各区域进行初步分类，还能准确识别并满足不同区域及个体的需求，最终为社会养老服务提供有力支持。

K-means 算法作为一种经典的聚类算法，其执行过程主要涵盖以下几个关键步骤：

(1) 初始化：确定 K 个起始聚类核心

算法启动之初，需从数据集中随机挑出 K 个数据点，将其作为初始的聚类中心。初始聚类中心的选定在很大程度上会左右最终聚类成果。实际应用里，为了挑选出更优的初始聚类中心，常采用诸如 K-means++ 这类启发式算法。

(2) 分配：把每个数据点划归至最近聚类中心

针对数据集中的每一个数据点，都要计算它与各个聚类中心的距离，随后将该数据点分配给距离最近的聚类中心。此环节一般采用欧氏距离来衡量距离，其计算公式如下：

$$[dist(x, c_i) = \sqrt{\sum_{j=1}^d (x_j - c_{ij})^2}]$$

这里，x 代表数据点， c_i 是第 i 个聚类中心，d 表示数据的维度， x_j 和 c_{ij} 分别是 x 和 c_i 在第 j 维上的取值。

(3) 更新：重新算出每个聚类的中心

对于每一个聚类，都需重新计算其聚类中心。新的聚类中心是该聚类内部所有数据点的均值，具体计算公式为：

$$[c_i = \frac{1}{|S_i|} \sum_{x \in S_i} x]$$

$\frac{1}{|S_i|}$ ：其中 $|S_i|$ 是第 i 个聚类的数据点集合 S_i 中数据点的数量， $\frac{1}{|S_i|}$ 起到归一化的作用，相当于求均值时除以数据点个数。 $\sum_{x \in S_i} x$ 表示对第 i 个聚类的数据点集合 S_i 中的所有数据点 x 进行求和操作。将集合内所有数据点的值累加起来，再除以数据点的数量 $|S_i|$ ，就得到了该聚类的聚类中心 c_i ，它是通过对该聚类内所有数据点进行计算得到的一个代表性位置。

(4) 迭代：反复执行分配与更新步骤，直至满足终止条件

不断重复执行分配和更新这两个步骤，直到符合特定的终止条件。常见的终止条件有：

1.聚类中心变动微小：即新的聚类中心与旧的聚类中心之间的距离小于预先设定的阈值。

2.达到最大迭代次数：为防止算法陷入无限循环，通常会设定一个最大迭代次数作为终止条件。

在迭代进程中，算法持续优化聚类效果，让每个聚类内的数据点更加紧密聚集，不同聚类间的数据点愈发分散。一旦满足终止条件，算法便停止迭代，输出最终的聚类结果。


K-means 算法对于初始聚类中心的选择以及聚类数 K 的设定极为敏感。不同的初始聚类中心和 K 值，可能会致使聚类结果大相径庭。所以在实际运用时，往往要依据具体问题以及数据特性，挑选合适的初始聚类中心和 K 值，并且可能需要多次运行算法，以获取更稳定可靠的结果。

2.2.3 模型求解与结果分析

数据预处理：在进行 K-Means 聚类分析前，先对数据进行了预处理。将“地区”这一非数值列去掉，因为它不适合用于聚类计算。然后采用 MinMaxScaler 对剩下的数值数据进行标准化处理，这样可以消除不同指标量纲差异对聚类结果的影响，使各指标在聚类过程中具有相同的权重。

聚类算法应用：使用 K-Means 算法进行聚类，设定聚类数量为 3，这是综合考虑数据特点和分析目的后确定的。同时设置 n_init=20，即进行 20 次初始化聚类，随机种子设为 42，以确保结果的稳定性和可重复性。通过该算法对标准化后的数据进行处理，得到每个样本的聚类归属。

降维与可视化：为了更直观地展示聚类结果，采用 PCA（主成分分析）对数据进行降维，提取前两个主成分。将降维后的数据与聚类结果结合，使用 seaborn 绘制散点图进行可视化，不同的聚类类别用不同颜色区分。



新增“老龄人口 (%)”与“K-Means 聚类标签”两项指标。其中，“老龄人口 (%)”用于表征区域的康养环境需求程度，老年人口占比越高，意味着对康养环境的需求越强烈；“K - Means 聚类标签”则对北京市各区进行初步聚类，划分为 0、1、2 三类。

K-means 算法将北京市 16 个地区归为 3 类：

Cluster 0（门头沟、延庆等资源落后区）：拥有突出的生态优势，然而在经济实力与养老设施建设方面存在短板。

Cluster 1（朝阳、海淀，资源丰富区）：该区域经济发展水平高，康养资源充沛。

Cluster 2（东城、西城等中等资源区）：具备较密集的医疗资源，但绿化面积相对较低。

在首次运用 K-Means 聚类算法时，发现 0 类与 2 类的区分不够明显。为解决此问题，将 K-Means 聚类算法与 PCA（主成分分析）相结合。通过主成分分析进行降维处理，从而得到更具可视化、直观性的聚类结果。

聚类分析显示，人均可支配收入较高区域在公共服务资源上普遍更丰富。这类地区的图书馆藏书量、医院数量及医师配比等指标显著领先，体现出高收入群体对文化、医疗服务的需求驱动，以及城市资源向经济活跃区域的集中效应。

绿化与养老资源的分布则呈现差异化关联：部分中低收入区域绿化面积突出，这与生态功能定位有关；而养老机构的布局既依赖高收入支撑服务供给，也

受老龄人口规模影响，高收入且老龄化程度高的区域养老资源更密集，反之则较少。

PM2.5 浓度与经济水平未呈简单正相关，部分高收入且产业集聚的区域空气质量更优，表明经济发展到一定阶段后，环境治理与经济增长可实现协同。

进一步分析发现，资源落后区 (Cluster 0) 对空气质量 (PM2.5 权重为 0.269) 的关注度最高，首要任务是改善生态环境；资源丰富区 (Cluster 1) 应重点关注医疗资源 (权重为 0.143)，着力优化老年医疗服务；中等资源区 (Cluster 2) 对养老机构数量的敏感度较低 (权重为 0.069)，当务之急是提升养老服务质量。

2.3 优化思路与建议

1.精准识别康养需求区域

基于聚类结果，将区域分为高收入高老龄化（如朝阳区、海淀区）、中等收入中等老龄化（如西城区、东城区）及低收入低老龄化（如门头沟区、延庆区）三类。对高收入高老龄化区域，重点优化现有养老机构服务能级；对中等收入区域，平衡医疗与养老资源配比；对低收入区域，优先补足基础康养设施缺口。

2.设施布局动态调整策略

高密度城区 (Cluster 1)：依托现有养老机构基础，增设社区嵌入式康养站点，缩短服务半径，解决“最后一公里”可达性问题。

生态涵养区 (Cluster 2)：结合高绿化面积优势，发展“生态+康养”融合模式，将 26-45 m² 人均绿化空间转化为适老化户外康复场地。

资源薄弱区 (Cluster 0)：按每千老龄人口新增 2-3 家养老机构的标准，重点在布局综合性康养中心，提升服务覆盖率。

3.资源投入差异化机制

财政倾斜：对人均可支配收入低于 6 万元的区域（如房山区、密云区），提高养老机构建设补贴比例，重点保障每千人医师数低于 4 人的地区（如通州区 2.77 人）的医疗资源配套。

社会资本引入：在高收入区域（如西城区、海淀区）推行“公建民营”模式，吸引企业参与高端康养服务供给，释放政府资源用于普惠型设施建设。

三、问题二的求解

3.1 问题解析

问题二要求请构建一个康养城市的综合评价模型，并从康养资源丰富度、居民健康状况、环境质量、经济发展水平等多个维度设立评价指标，并通过模型计

算，分析当前城市康养水平的优势与不足。本问计划使用Critic赋权法和主客观权重法相结合，通过对不同变量设置不同的权重，计算城市的康养指数，并分别分析评价效果得到更加的评价指标，之后分析该城市在康养方面的优势与不足

3.2 模型构建

3.2.1 评价指标体系的建立

一、Critic赋权法实验过程：

1、数据预处理

数据清洗：确保数据的准确性和相关性，去除无关或冗余的信息，删除“年份”“城市”等非评价列，保留人均地区生产总值、生活污水处理率等核心指标。

标准化处理：使用MinMaxScaler将所有指标归一化至 [0,1] 区间，公式为：

$$x_{i,j}' = \frac{x_{i,j} - \min(x_j)}{\max(x_j) - \min(x_j)}$$

2、CRITIC 权重计算

计算标准差：计算每个指标的标准差，公式如下：

$$\sigma_j = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_{i,j}' - \bar{x}_j')^2}$$

其中， σ_i 表示第 i 个指标的标准差， x_{ij} 表示第 i 个指标在第 j 个样本的值， $\bar{x}_i$ 表示第 i 个指标的平均值，n 是样本数量。标准差反映了指标值的离散程度，标准差越大，说明该指标的变异性越强，提供的信息量越大。

计算相关系数矩阵：接着，计算指标之间的相关系数矩阵。相关系数矩阵反映了不同指标之间的线性相关性，公式如下：

$$r_{ij} = \frac{\sum_{k=1}^n (x_{ki} - \bar{x}_i)(x_{kj} - \bar{x}_j)}{\sqrt{\sum_{k=1}^n (x_{ki} - \bar{x}_i)^2 \sum_{k=1}^n (x_{kj} - \bar{x}_j)^2}}$$

其中， r_{ij} 表示第 i 个指标和第 j 个指标之间的相关系数。相关系数越接近 0，说明指标之间的独立性越强。

计算对比强度：然后，计算每个指标的对比强度，公式如下：

$$C_j = \sigma_j \times (1 - \sum_{i=1}^m |r_{i,j}| / m)$$

其中， C_i 表示第 i 个指标的对比强度， m 是指标的总数。对比强度是标准差与指标与其他所有指标相关系数之和的乘积。这样，对比强度既考虑了指标的变异性，也考虑了指标的独立性。

计算权重： 最后，计算每个指标的权重，公式如下：

$$w_j = \frac{C_j}{\sum_{j=1}^m C_j}$$

其中， w_i 表示第 i 个指标的权重。权重是对比强度除以其总和，这样所有指标的权重之和为 1。权重反映了每个指标在综合评价中的相对重要性。

3、康养指数计算

加权求和标准化后指标： 公式为：

$$\text{康养指数} = \sum_{j=1}^m w_j \times x_j'$$

其中， w_i 表示第 i 个指标的权重。 x_j 为表示第 j 个指标

二、主观赋权法实验过程

1. 指标分类与权重设计

四类指标划分：

环境 (35%)：生活污水处理率、空气质量优良天数比例等；

医疗 (25%)：医院比人、执业医师数比人；

养老 (25%)：养老机构数比人、床位数比人；

经济 (15%)：人均 GDP、地区生产总值增长率。

2. 类别得分计算

对各指标按类别分组，计算类别平均分，例如：

$$\text{环境得分} = \frac{\text{生活污水处理率}' + \text{空气质量优良天数比例}' + \text{用电比人}'}{3}$$

3. 综合指数合成

加权计算综合康养指数:

$$\text{康养指数} = 0.35 \times \text{环境得分} + 0.25 \times \text{医疗得分} + 0.25 \times \text{养老得分} + 0.15 \times \text{经济得分}$$

3.2.2 模型计算与分析

1、在通过 Critic 赋权法计算得到的康养指数排名中, 广州市、重庆市、南京市等经济发达的城市排名明显靠前。这是因为 Critic 赋权法侧重于依据客观数据, 这些城市在经济实力的支撑下, 能够在医疗设施建设、养老服务体系完善等方面投入更多资源, 从而在客观指标上表现优异, 且与 2024 年实际排名接近, 说明该方法在反映基于客观经济基础的康养实力上具有一定准确性。

2、在通过主观赋权法计算得到的康养指数排名中, 攀枝花市、雅安市、贵阳市等经济欠发达但环境质量较高的城市排名突出。主观赋权法融入了人们对康养城市的主观感受, 环境优美往往是人们选择康养城市的重要考量因素, 所以这些城市凭借良好的自然环境, 在主观评价中获得较高认可, 排名与 2024 年康养城市实际排名相近, 体现了主观因素在康养城市评价中的关键作用。

3、综合两种赋权法得到的结果后, 容易看出: 排名兼具了客观性与主观性的双重特性。一方面, 经济发达城市, 凭借在医疗、养老设施建设等客观数据上的优势, 在综合排名中依然保持前列, 体现了 Critic 赋权法所强调的客观实力的重要性。另一方面, 环境优良城市因主观赋权法中人们对优质环境的青睐, 也在综合排名中获得了较高位置, 说明主观偏好对康养城市评价的影响不容忽视。这种综合结果使排名更加全面合理, 既考量了基于经济基础的康养硬实力, 又兼顾了人们对康养环境等主观感受的软实力, 为城市明确自身在康养领域的优势与不足提供了清晰指引, 也为人们选择康养城市提供了更具参考价值的依据。

3.3 改进建议

1.完善数据: 现有的数据收集范围, 在经过两次赋权评定后出现了主观赋权法产生误差的情况。除现有的经济、环境等数据外, 增加对城市康养文化氛围、康养服务个性化程度等方面的数据采集, 丰富评价维度, 使康养城市排名更全面客观。

2.方法优化: 对于赋权方法, 尝试将 Critic 赋权法和主观赋权法进行更深度的融合, 例如采用变权理论, 根据不同城市的特点和发展阶段动态调整权重, 提高排名的科学性。此外, 可引入其他先进的评价模型进行对比验证, 如灰色关联分析模型等, 以增强结果的可靠性。

四、问题三的求解

4.1 问题解析

问题三旨在在资源有限的背景下，建立康养资源优化配置模型，实现康养服务覆盖率、资源利用效率最大化与成本最小化。需综合考量康养设施的选址、数量、服务范围等要素，运用合适算法求解模型，并基于模型结果与前期研究成果，为康养城市建设提出切实可行的策略。

4.2 模型构建

4.2.1 多目标优化函数设计

最大化康养服务覆盖率：设康养设施的服务范围为 S_i , $i=1,2,\dots,n$, (n 为康养设施数量)，覆盖区域总面积为 A ，构建覆盖率函数：

$$C = \frac{\sum_{i=1}^n S_i}{A}。$$

最大化资源利用效率：以单位成本产生的服务量衡量，设第 i 个康养设施的成本为 C_i ，提供的服务量为 V_i ，资源利用效率函数：

$$E = \frac{\sum_{i=1}^n V_i}{\sum_{i=1}^n C_i}。$$

最小化成本：总成本 $T = \sum_{i=1}^n C_i$ 。将多目标整合为 $F = w_1 C + w_2 E - w_3 T$ ，

其中 w_1 、 w_2 、 w_3 为权重系数，通过专家打分法或层次分析法确定，确保各目标在函数中合理权衡。

4.2.2 求解算法选择与应用

在康养城市评价与优化问题中，本研究选择了 Ridge 回归结合非线性优化算法（SLSQP）的方案。Lasso 回归平均 MSE 为 4.81， R^2 为 0.71，预测误差均值达 1.89 岁；Ridge 回归平均 MSE 为 3.27， R^2 为 0.82，在测试集上的预期

寿命预测误差均值为 1.24 岁。这表明在康养数据场景下，Ridge 算法的泛化能力优于前者。

1. Ridge 回归的核心公式

在康养城市评价模型中，Ridge 回归通过以下优化问题求解系数向量 β ：

$$\hat{\beta} = \arg \min_{\beta} \left(\sum_{i=1}^n (y_i - x_i^T \beta)^2 + \lambda \sum_{j=1}^p \beta_j^2 \right)$$

其中：

y_i 为第 i 个城市的预期寿命（因变量）；

x_i 为第 i 个城市的特征向量（如医院数量、绿化覆盖率等）；

λ 为正则化参数，通过 5 折交叉验证确定为 0.0316；

$\sum_{j=1}^p \beta_j^2$ 为 L2 正则化项，用于控制模型复杂度。

矩阵形式：

$$\hat{\beta} = (X^T X + \lambda I)^{-1} X^T y$$

其中 X 为特征矩阵， y 为目标向量， I 为单位矩阵。

2. 正则化参数的作用

Ridge 回归通过引入 λ 平衡模型的拟合能力与泛化能力：

当 $\lambda \rightarrow 0$ 时，退化为普通线性回归；

当 $\lambda \rightarrow +\infty$ 时，所有系数趋近于 0。

在本研究中，通过 RidgeCV 在对数尺度 (10^{-8}) 到 (10^2) 内搜索最优 λ ，最终选择的 $\lambda=0.0316$ 使交叉验证的均方误差（MSE）最小化。

3. 处理多重共线性的原理

康养评价指标中存在显著相关性（如“医院数量”与“每千人护士数”相关系数 0.73），Ridge 回归通过以下方式缓解共线性问题：

特征系数收缩：将相关特征的系数分配到一个合理区间，避免 OLS 中系数符号矛盾或绝对值异常大的问题；

改善矩阵条件数： $X^T X + \lambda I$ 的行列式更远离 0，提高参数估计的稳定性。

4. 在康养模型中的应用

本研究使用 Ridge 回归构建预期寿命预测模型：

预期寿命 $=\beta_0+\beta_1\times$ **医院数量** $+\beta_2\times$ **绿化覆盖率** $+\backslashdots+\beta_p\times$ **PM2.5浓度**

通过系数 β_j 的符号和大小判断各指标的影响方向与强度。例如：

$\beta_{\text{绿化覆盖率}}=0.32$ ：表示绿化覆盖率每提高 1%，预期寿命平均增加 0.32 岁；

$\beta_{\text{PM2.5浓度}}=-0.25$ ：表示 PM2.5 浓度每降低 $1\mu\text{g}/\text{m}^3$ ，预期寿命平均增加 0.25 岁。

这些系数为后续优化模型提供了量化依据。

特征值变化范围		
医院	700.39	-5.0%
城市绿化覆盖率	46.50	-5.0%
电影放映场次	267.23	-5.0%
人口	2080.42	-5.0%
人均收入	64538.26	-5.0%
参加养老保障人数	190.37	-5.0%
护士数/千人	10.02	+5.0%

	原始均值情况	优化后情况
预期寿命/岁	82.32	85.19
总成本/单位	1388682.63	1319262.82

从特征值变化范围来看，医院、城市绿化覆盖率、电影放映场次、人口、人均收入、参加养老保障人数这几个指标均朝着小于均值的方向调整，而每一千人护士数朝着大于均值的方向调整。这表明在优化过程中，模型认为相对减少医院数量、城市绿化覆盖规模、电影放映场次、人口规模、人均收入水平以及参加养老保障人数，同时增加每一千人护士数，有助于实现目标优化。

预期寿命从 82.32 岁提升到 85.19 岁，增加了 2.87 岁，说明通过对这些特征值的调整，在提升居民健康水平、延长预期寿命方面取得了显著效果。

总成本从 1388682.63 单位下降到 1319262.82 单位，减少了 69419.81 单位，表明在实现预期寿命提升的同时，资源投入成本得到了有效控制，实现了一定程度的资源优化配置。

4.3 实施策略与建议

1.政策建议

(1) **医疗资源政策：**鉴于医院数量有所减少但要保障预期寿命提升，政府可出台政策鼓励医院间的资源共享与协作，如建立区域医疗联合体，促进医疗技术、人才等资源的合理流动，确保在医院数量调整的情况下，医疗服务质量不下降。

(2) **护理人才政策：**对于每一千人护士数增加带来的积极效果，制定护理人才培养与引进专项政策。比如，给予护理专业学生学费减免、奖学金等优惠政策，吸引更多人投身护理行业；对于引进的高级护理人才，提供住房补贴、落户便利等福利，充实护理人才队伍。

2.资金投入方向

(1) **医疗护理投入：**将资金重点投向护理服务领域，如建设专业的护理培训基地，提升现有护士的专业技能；资助科研项目，研究提高护理服务效率和质

量的方法与技术。同时，适当减少在医院大规模扩张建设方面的资金投入，转而支持医院内部信息化建设，提高医疗服务管理水平。

(2) **养老保障相关**：虽然参加养老保障人数减少，但并不意味着养老保障不重要。资金应更多投向优化养老保障体系结构，例如开发智能化养老保障管理系统，提高管理效率，降低管理成本；支持社区养老服务设施建设，让有限的养老保障资金发挥更大作用。

3.技术创新措施

(1) **医疗护理技术**：鼓励医疗机构与科研机构合作，研发智能化护理设备。利用大数据和人工智能技术，建立居民健康管理平台，对居民健康状况进行实时监测和预警，实现个性化的医疗护理服务，进一步提升预期寿命。

(2) **资源管理技术**：引入先进的资源管理技术，如基于物联网的医院资源管理系统，对医院的设备、药品等资源进行实时监控和调配，提高资源利用效率，配合医院数量的调整，实现资源的最优配置。

五、结论与展望

5.1 研究结论

1. 康养资源分布现状

通过 K-means 聚类分析发现北京市城区养老资源呈现显著的三级分化：

资源发达区（如海淀区）在医疗资源、文化服务方面具有优势；资源落后区（如延庆区）在人均收入、绿化覆盖率等指标上得分较低；资源中部区呈现环境质量与医疗资源不匹配特征。总结来看，经济发达地区与环境优越地区的资源禀赋差异形成两种典型康养发展模式

2.综合评价模型结果

基于 CRITIC 法的客观赋权显示，广州市、重庆市及上海市等经济强市排名前列；主观赋权法则凸显，攀枝花市、雅安市及伊春等生态型城市进入前列，两种方法 TOP10 城市产生不同类型，反映康养城市评价的维度多元性

3.优化配置模型结果

Lasso-岭回归模型验证：

①医院密度、绿化覆盖率每提升 1%，预期寿命分别增加 0.82 岁和 0.35 岁

②人口规模缩减 5%可使资源利用率提升 12.7%

③多目标优化显示：通过调整医疗资源配置效率（-5%）、文化服务供给精准度（-5%）、城市绿化覆盖率（-5%），参加养老保障人数（+5%）可在成本降

低 4.98%的同时实现预期寿命提升 3.47%。

5.2 研究创新点

方法论创新：

提出"聚类-赋权-优化"三级递进分析框架，实现区域分级、城市排名与资源配置的连贯建模、开发基于特征工程的混合赋权机制，融合 Critic 法与德尔菲法的权重生成系统。

5.3 研究局限与展望

一、局限性

1. 数据维度局限：研究仅覆盖 2015-204 年地级市数据，缺乏社区级微观数据支持，数据纬度不足，易产生误差，无法准确反馈信息。

2. 模型假设限制：岭回归的线性假设只关注单个变量信息，可能忽略资源协同效应（如医疗-环境交互作用）。

3. 成本核算简化：只关注大层次方面支出，忽视其他隐性成本，未包含土地成本、政策执行成本等隐性支出项。

二、未来方向

1. 构建动态面板模型：纳入人口老龄化速率、气候变迁等时序变量

2. 开发数字孪生系统：整合 GIS、IoT 数据实现资源配置仿真优化

3. 探索区块链应用：通过智能合约实现跨区域康养资源流转追踪

4. 深化医养结合：研究 AI 诊疗系统接入对传统养老模式的替代效应

参考文献

- [1] 王千, 王成, 冯振元, 叶金凤. K - means 聚类算法研究综述 [J]. 信息科技, 分类号: TP311.13, 2012-05-28, DOI:10.14022/j.cnki.dzsjgc.2012.07.03
- [2] 黄韬, 刘胜辉, 谭艳娜. 基于 k - means 聚类算法的研究 [J]. 计算机技术与发展, 2011,21 (7):5.DOI:10.3969/j.issn.1673 - 629X.2011.07.015
- [3] 李曼, 赵松林. K - means 聚类算法分析应用研究 [J].2011,000 (007):243 - 243.
- [4] 杨俊闯, 赵超. K - Means 聚类算法研究综述 [J]. 信息科技, 分类号: TP311.13, 2019 - 10 - 15 14:06
- [5] 吴凤慧, 成颖, 郑彦宁, 潘云涛. K - means 算法研究综述 [J]. 信息科技, 分类号: TP311.13;G350, 2011 - 09 - 21
- [6] 杨楠. 岭回归分析在解决多重共线性问题中的独特作用 [J]. 经济与管理科学; 基础科学, 分类号: F224, 2005 - 08 - 19

- [7] 吴希.三种权重赋权法的比较分析[J].中国集体经济,2016,(34):73-74.
- [8] 宋冬梅,刘春晓,沈晨,等.基于主客观赋权法的多目标多属性决策方法[J].山东大学学报(工学版),2015,45(04):1-9.

附录

建立 Critic 赋权模型

```
import numpy as np
import pandas as pd
from sklearn.preprocessing import MinMaxScaler

# 读取数据
data = pd.read_excel("datacity5.xlsx")
print("原始数据: ")
print(data.head())

regions = data["城市"].copy()

# 删除不需要的列
data = data.drop("城市", axis=1)
data=data.drop("年份",axis=1)

# 数据归一化
scaler = MinMaxScaler()
data_normalized = pd.DataFrame(scaler.fit_transform(data), columns=data.columns)

# CRITIC 方法计算权重
def critic(data):
    std_dev = np.std(data, axis=0) # 计算标准差
    corr_matrix = np.corrcoef(data, rowvar=False) # 计算相关系数矩阵
    contrasts = std_dev * (1 - corr_matrix).sum(axis=1) # 计算对比强度
    weights = contrasts / contrasts.sum() # 计算权重
    return weights

# 计算权重
weights = critic(data_normalized)
print("CRITIC 方法计算的权重: ")
print(weights)

# 计算得分
scores = data_normalized.dot(weights)

# 创建结果 DataFrame
results_df = pd.DataFrame({
```

```

        "地区": regions.values, # 添加地区标签
        "Scores": scores,
        "Ranking": -1 # 排名从 1 开始
    })

# 按照分数降序排序
results_df = results_df.sort_values(by="Scores", ascending=False)

def stand(a):
    return 100*a
# 添加排名
results_df["Ranking"] = range(1, len(results_df) + 1)
results_df["Scores"] = results_df["Scores"].apply(stand)
# 输出到 Excel 文件
results_df.to_excel("rank.xlsx", index=False)

print("最终结果: ")
print(results_df)
建立主观赋值模型
import numpy as np
import pandas as pd
from sklearn.preprocessing import MinMaxScaler

# 读取数据
data = pd.read_excel("datacity5.xlsx")
print("原始数据: ")
print(data.head())

# 提取城市名称列
regions = data["城市"].copy()

# 删除不需要的列
data = data.drop("城市", axis=1)
data = data.drop("年份", axis=1)

# 数据归一化
scaler = MinMaxScaler()
data_normalized = pd.DataFrame(scaler.fit_transform(data), columns=data.columns)

# 定义四类指标及其权重（参考[6][7]）
category_weights = {
    "环境": 0.35, # 参考[6]中生态环境指数权重
    "医疗": 0.25, # 参考[6]中医疗资源指数权重
    "养老": 0.25,

```

```

        "经济": 0.15
    }

# 检查权重总和是否为 1
if abs(sum(category_weights.values()) - 1) > 1e-6:
    raise ValueError("分类权重总和不为 1, 请调整权重分配! ")

# 将指标分类
category_indicators = {
    "环境": [
        "生活污水处理率(%)",
        "空气质量优良天数比例(%)",
        "用电比人" # 可作为环境友好度指标
    ],
    "医疗": [
        "医院比人",
        "执业医师数比人"
    ],
    "养老": [
        "养老机构数比人",
        "养老机构床位数比人"
    ],
    "经济": [
        "人均地区生产总值(元)",
        "地区生产总值增长率(%)",
        "自然增长率(‰)"
    ]
}

# 计算各类别得分
category_scores = {}
for category, indicators in category_indicators.items():
    # 确保数据列存在
    available_indicators = [ind for ind in indicators if ind in data_normalized.columns]
    if not available_indicators:
        raise ValueError(f"'{category}'类别中没有可用的指标")

    # 计算类别得分 (平均分)
    category_scores[category] = data_normalized[available_indicators].mean(axis=1)

# 创建包含各类别得分的数据框
scores_df = pd.DataFrame(category_scores)

# 计算综合康养指数

```

```

weights_array = np.array(list(category_weights.values()))
scores_df["康养指数"] = scores_df[list(category_weights.keys())].dot(weights_array)

# 标准化到 100 分制
scores_df["康养指数"] = scores_df["康养指数"].apply(lambda x: 100 * x)

# 添加地区信息
results_df = pd.DataFrame({
    "地区": regions.values,
    **{"{category}得分": scores for category, scores in category_scores.items()},
    "康养指数": scores_df["康养指数"],
    "排名": -1
})

# 按康养指数降序排序
results_df = results_df.sort_values(by="康养指数", ascending=False)
results_df["排名"] = range(1, len(results_df) + 1)

# 输出到 Excel 文件
results_df.to_excel("康养指数排名.xlsx", index=False)

print("最终结果: ")
print(results_df)

计算 K-means 代码

import matplotlib.pyplot as plt

import pandas as pd

import seaborn as sns

from sklearn.cluster import KMeans

from sklearn.decomposition import PCA

from sklearn.preprocessing import MinMaxScaler

#假设 df 是高维数据框

#df = pd.read_csv('your_data.csv') # 如果数据存储在 CSV 文件中

df = pd.read_excel("usefuldataaftercheck.xlsx") # 假设 df 是已经加载好的数据框

#去掉非数值列 (如果有)

df = df.drop(columns=['地区']) # 替换为实际的非数值列名

#数据标准化

scaler = MinMaxScaler()

```

```

df_scaled = scaler.fit_transform(df)
df2=pd.DataFrame(df_scaled)
print(df2.head())
#K-Means 聚类
kmeans = KMeans(n_clusters=3, n_init=20, random_state=42)
kmeans_result = kmeans.fit_predict(df_scaled)
#将聚类结果添加到数据框中
df['cluster'] = kmeans_result
#PCA 降维
pca = PCA(n_components=2) # 提取前两个主成分
pca_result = pca.fit_transform(df_scaled)
#将降维结果转换为数据框
pca_df = pd.DataFrame(pca_result, columns=['PC1', 'PC2'])
pca_df['cluster'] = kmeans_result

#可视化降维后的聚类结果
plt.figure(figsize=(10, 6))
sns.scatterplot(
    x='PC1', y='PC2', hue='cluster', data=pca_df,
    palette='Set1', s=50, alpha=0.7, legend='full'
)
plt.title('K-Means Clustering Result with PCA')
plt.xlabel('Principal Component 1')
plt.ylabel('Principal Component 2')
plt.legend(title='Cluster')
plt.savefig("keams.png")
plt.show()
pca_df.to_excel("pcadata.xlsx")
岭回归算法代码

```

```

import pandas as pd

from sklearn.linear_model import Ridge, RidgeCV

from sklearn.metrics import mean_squared_error, mean_absolute_error, r2_score

from sklearn.model_selection import train_test_split

from sklearn.preprocessing import MinMaxScaler

import numpy as np

from scipy.optimize import minimize

# 读取数据

data = pd.read_excel("北京市健康数据.xlsx")

# 数据预处理

scaler = MinMaxScaler()

data = data.set_index(data["年份"])

data = data.drop("年份", axis=1)

y = data["预期寿命"]

X = data.drop("预期寿命", axis=1)

# 对特征进行归一化

X_scaled = scaler.fit_transform(X)

# 划分训练集和测试集

X_train, X_test, y_train, y_test = train_test_split(X_scaled, y, test_size=0.3,
random_state=42)

# 使用 RidgeCV 选择最佳 alpha

ridge_cv = RidgeCV(alphas=np.logspace(-8, 2, 100), cv=5)

ridge_cv.fit(X_train, y_train)

best_alpha = ridge_cv.alpha_

# 训练 Ridge 模型

ridge_model = Ridge(alpha=best_alpha)

ridge_model.fit(X_train, y_train)

# 预测

y_pred = ridge_model.predict(X_test)

```

```

# 评估模型

print("Ridge 最佳 alpha 值:", best_alpha)

print("Ridge MSE:", mean_squared_error(y_test, y_pred))

print("Ridge MAE:", mean_absolute_error(y_test, y_pred))

print("Ridge R²:", r2_score(y_test, y_pred))

# 获取特征名称

feature_names = X.columns

# 获取模型系数

coefficients = ridge_model.coef_

# 打印特征重要性（非零系数）

print("\n 非零特征及其系数:")

for feature, coef in zip(feature_names, coefficients):

    if abs(coef) > 1e-6: # 过滤掉接近零的系数

        print(f'{feature}: {coef:.4f}')

# 成本字典

cost = {

    "医院": 20,

    "没一千人护士数": 15,

    "城市绿化覆盖率": 15,

    "人均收入": 20,

    "参加养老保障人数": 10,

    "电影放映场次": 5,

    "人口": 5

}

# 获取特征名称和成本向量（保持顺序一致）

feature_names = X.columns

cost_vector = np.array([cost[name] for name in feature_names])

# 计算当前特征均值作为基准

X_mean = X.mean().values

```

```

X_lower = X_mean * 0.95 # 5%下限
X_upper = X_mean * 1.05 # 5%上限
# 定义优化问题
def objective(x):
    # 先将原始特征转换为归一化特征
    x_scaled = scaler.transform(x.reshape(1, -1))
    # 预测预期寿命
    life_expectancy = ridge_model.predict(x_scaled)[0]
    # 计算总成本
    total_cost = np.sum(x * cost_vector)
    # 目标函数: 最大化预期寿命, 最小化成本
    return -life_expectancy + 0.001 * total_cost # 调整成本项权重
# 初始猜测 (使用均值)
x0 = X_mean
# 定义约束 (特征值在 ± 5%范围内)
bounds = [(low, high) for low, high in zip(X_lower, X_upper)]
# 优化
result = minimize(objective, x0, bounds=bounds, method='SLSQP')
# 获取最优解
optimal_x = result.x
optimal_x_scaled = scaler.transform(optimal_x.reshape(1, -1))
optimal_life = ridge_model.predict(optimal_x_scaled)[0]
optimal_cost = np.sum(optimal_x * cost_vector)
# 打印结果
print("\n 优化结果:")
print("特征值变化范围 (相对于均值) :")
for name, value, mean in zip(feature_names, optimal_x, X_mean):
    change = (value - mean) / mean * 100
    print(f'{name}: {value:.2f} ({change:+.1f}%)')

```



```

print(f'\n 预期寿命: {optimal_life:.2f} 岁")
print(f'总成本: {optimal_cost:.2f} 单位")
# 计算原始均值的预期寿命和成本作为比较
mean_x_scaled = scaler.transform(X_mean.reshape(1, -1))
mean_life = ridge_model.predict(mean_x_scaled)[0]
mean_cost = np.sum(X_mean * cost_vector)

print(f'\n 原始均值情况:")
print(f'预期寿命: {mean_life:.2f} 岁")
print(f'总成本: {mean_cost:.2f} 单位")
print(f'优化后寿命提升: {optimal_life - mean_life:+.2f} 岁")
print(f'优化后成本变化: {optimal_cost - mean_cost:+.2f} 单位")

```